KHÓA LUẬN TỐT NGHIỆP

Personalized Federated Heterogeneous Graph Learning for Credit Risk Prediction

BÁO CÁO: CÁCH CHIA DỮ LIỆU CHO FEDERATED LEARNING

Bộ dữ liệu: Home Credit Default Risk (Kaggle)

Người thực hiện: Anh Thu

Ngày cập nhật: 07/10/2026

Mã nguồn: nhánh git main (repo home_credit_fedheterognn)

1. Tổng quan

Để huấn luyện theo hướng Federated Learning, dữ liệu Home Credit được chia cho 5 tổ chức tín dụng mô phỏng. Kịch bản chính region_territory_a0.5 chia khách hàng theo vùng sinh sống, dùng cột REGION_POPULATION_RELATIVE làm mã vùng; Dirichlet(α = 0.5) chỉ quyết định quy mô của từng tổ chức. Báo cáo này trình bày lý do chọn cách chia, quy trình chia, ý nghĩa thực tiễn, kết quả lặp lại qua 3 seed huấn luyện và các hạn chế cần cải thiện.

2. Lý do chia theo vùng

2.1. Cần mô phỏng các tổ chức có thật

Home Credit là một tổ chức duy nhất, nên muốn làm Federated Learning thì phải tự chia dữ liệu thành nhiều tổ chức. Ngoài thực tế, các tổ chức tín dụng (ngân hàng địa phương, chi nhánh, công ty tài chính khu vực) thường hoạt động theo địa bàn. Vì vậy chia theo vùng hợp lý hơn chia ngẫu nhiên hay chia theo nhãn.

2.2. REGION_POPULATION_RELATIVE dùng được làm mã vùng

Dữ liệu không có cột mã vùng. Theo mô tả của Home Credit, REGION_POPULATION_RELATIVE là mật độ dân số đã chuẩn hóa của vùng khách hàng sinh sống. Kiểm tra dữ liệu cho thấy cột này:

- chỉ có 81 giá trị rời rạc, không phải số liên tục cho từng khách hàng;
- mỗi giá trị ứng với đúng một REGION_RATING_CLIENT (100% trường hợp).

Vì vậy mỗi giá trị được coi là một vùng đã ẩn danh. Đây là suy luận từ dữ liệu đã ẩn danh và được ghi nhận là giả định. Các cột vùng khác không thay thế được: REGION_RATING_CLIENT và REGION_RATING_CLIENT_W_CITY chỉ có 3 mức, quá thô để chia cho 5 tổ chức mà mỗi vùng vẫn thuộc trọn một tổ chức.

2.3. Không dùng TARGET khi chia

- Mỗi vùng được giao trọn cho một tổ chức. Dirichlet(α = 0.5) chỉ quyết định quy mô của từng tổ chức: nhỏ nhất 3.2%, lớn nhất 47.4% số khách hàng.
- Khác biệt về đặc trưng giữa các tổ chức (thu nhập, EXT_SOURCE…) tự xuất hiện từ các vùng mà tổ chức phụ trách. Tỷ lệ vỡ nợ chỉ chênh nhẹ, từ 7.6% đến 9.3%, sát với thực tế.
- Để so sánh, kịch bản label_dirichlet_a0.5 (Dirichlet trên TARGET) tạo ra một tổ chức có 72% khách hàng vỡ nợ. Kịch bản này phi thực tế nên chỉ được giữ làm stress test.

3. Quy trình chia

Vùng sinh sống quyết định khách hàng thuộc tổ chức nào; Dirichlet quyết định mỗi tổ chức lớn bao nhiêu. Quy trình gồm bốn bước:

1. Quy mô: lấy mẫu q ~ Dirichlet(α = 0.5) cho 5 tổ chức. α càng nhỏ thì quy mô các tổ chức càng chênh lệch.
2. Địa bàn: xếp 81 vùng theo thứ tự ngẫu nhiên, lần lượt giao từng vùng cho tổ chức đang thiếu khách hàng nhiều nhất so với quy mô mục tiêu. Mỗi vùng được giao nguyên vẹn.

3. Khách hàng: khách hàng sống ở vùng nào thuộc tổ chức phụ trách vùng đó, kéo theo toàn bộ lịch sử tín dụng (bureau, previous, installments, POS, credit card).
4. Ràng buộc: loại lần lấy mẫu nếu có tổ chức dưới 3% khách hàng hoặc dưới 30 mẫu mỗi lớp ở Train/Validation/Test.

Bảng 1. Đặc điểm các tổ chức trong kịch bản region_territory_a0.5

Tổ chức	Khách hàng	Tỷ trọng	Số vùng	Tỷ lệ vỡ nợ
C0	34,805	11.3%	10	7.6%
C1	25,860	8.4%	5	8.5%
C2	9,866	3.2%	3	9.2%
C3	91,159	29.6%	23	8.2%
C4	145,821	47.4%	40	8.0%

4. Ứng dụng trong thực tiễn ngân hàng

Cách chia này ứng với tình huống nhiều tổ chức tín dụng, mỗi bên phục vụ một địa bàn, có cùng loại dữ liệu nhưng không được gộp dữ liệu khách hàng về một chỗ. Đây là Federated Learning theo chiều ngang (horizontal FL): các bên có cùng đặc trưng nhưng khác tập khách hàng.

Bảng 2. Các tình huống thực tế tương ứng với cách chia theo vùng

Tình huống	Vì sao khớp với cách chia theo vùng
Quỹ tín dụng nhân dân, ngân hàng hoặc công ty tài chính hoạt động theo địa phương	Mỗi đơn vị chủ yếu phục vụ khách hàng trong địa bàn mình, nên mỗi vùng thuộc một tổ chức. Đơn vị nhỏ có ít dữ liệu và ít ca vỡ nợ, khó tự xây mô hình tốt, giống tổ chức C2 chỉ có 3.2% khách hàng.
Tập đoàn tài chính có công ty con ở nhiều tỉnh hoặc nhiều quốc gia	Quy định về bảo vệ dữ liệu cá nhân hoặc lưu trữ dữ liệu trong nước có thể không cho chuyển dữ liệu khách hàng về trụ sở. FL cho phép chỉ gửi tham số mô hình.
Ngân hàng lớn chia theo vùng hoặc chi nhánh	Dữ liệu ở cùng một tổ chức nhưng hành vi tín dụng khác nhau giữa thành thị và nông thôn. Personalized FL (FedPer, Ditto) trả lời câu hỏi: nên dùng một mô hình chung hay tinh chỉnh riêng cho từng vùng?

Về cơ sở pháp lý, có thể tham chiếu Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân và quy định về bảo mật thông tin khách hàng trong Luật Các tổ chức tín dụng 2024.

5. Kết quả qua nhiều seed huấn luyện

Để kiểm tra kết luận có phụ thuộc vào một lần huấn luyện hay không, các mô hình Centralized HeteroGNN, Local-only, FedAvg và Ditto được huấn luyện lại với 3 seed (42, 1, 2) trên cùng cách chia region_territory_a0.5. Seed thay đổi khởi tạo trọng số và thứ tự batch; split Train/Validation/Test và cách chia client giữ nguyên. Khoảng tin cậy bootstrap ở báo cáo tiến độ chỉ phản ánh dao động do mẫu Test; độ lệch chuẩn qua seed bổ sung dao động do huấn luyện.

Bảng 3. ROC-AUC trên Test của từng client, trung bình ± độ lệch chuẩn qua 3 seed

Mô hình	C0	C1	C2	C3	C4	Trung bình	Kém nhất
Centralized HeteroGNN	0.7810 ± 0.0018	0.7737 ± 0.0014	0.7864 ± 0.0005	0.7872 ± 0.0009	0.7858 ± 0.0023	0.7847 ± 0.0016	0.7737 ± 0.0014
Local-only	0.7490 ± 0.0018	0.7422 ± 0.0036	0.7662 ± 0.0035	0.7702 ± 0.0021	0.7737 ± 0.0014	0.7670 ± 0.0011	0.7422 ± 0.0036
FedAvg	0.7793 ± 0.0020	0.7738 ± 0.0035	0.7774 ± 0.0018	0.7868 ± 0.0013	0.7845 ± 0.0016	0.7835 ± 0.0013	0.7731 ± 0.0023
Ditto	0.7803 ± 0.0018	0.7728 ± 0.0033	0.7837 ± 0.0040	0.7861 ± 0.0019	0.7810 ± 0.0003	0.7818 ± 0.0006	0.7728 ± 0.0033

"Trung bình" có trọng số theo số khách hàng Test của từng client; "Kém nhất" là AUC thấp nhất trong 5 client.

Bảng 4. Chênh lệch ROC-AUC qua 3 seed: trung bình ± độ lệch chuẩn (số seed có chênh lệch dương)

So sánh	C0	C1	C2	C3	C4	Trung bình
FedAvg − Local-only	+0.0303 ± 0.0034 (3/3)	+0.0317 ± 0.0060 (3/3)	+0.0112 ± 0.0030 (3/3)	+0.0166 ± 0.0009 (3/3)	+0.0108 ± 0.0003 (3/3)	+0.0165 ± 0.0009 (3/3)
FedAvg − Centralized HeteroGNN	−0.0016 ± 0.0037 (1/3)	+0.0002 ± 0.0044 (1/3)	−0.0090 ± 0.0013 (0/3)	−0.0004 ± 0.0019 (2/3)	−0.0013 ± 0.0039 (1/3)	−0.0012 ± 0.0029 (1/3)
Ditto − FedAvg	+0.0010 ± 0.0030 (2/3)	−0.0010 ± 0.0023 (1/3)	+0.0063 ± 0.0043 (3/3)	−0.0007 ± 0.0011 (1/3)	−0.0035 ± 0.0018 (0/3)	−0.0017 ± 0.0009 (0/3)
Ditto − Centralized HeteroGNN	−0.0007 ± 0.0027 (1/3)	−0.0009 ± 0.0034 (1/3)	−0.0027 ± 0.0040 (1/3)	−0.0011 ± 0.0027 (1/3)	−0.0049 ± 0.0022 (0/3)	−0.0029 ± 0.0020 (0/3)

Bảng 5. Kiểm định giả thuyết: 1 seed so với 3 seed

Giả thuyết	1 seed (seed 42)	3 seed	Kết luận
H1. FedAvg > Local-only	Đúng ở 4/5 client	Chênh lệch dương ở 5/5 client và 3/3 seed	Ổn định
H2. Tổ chức nhỏ được lợi nhiều hơn	C0, C1 ≈ +0.028; C4 +0.011	C0, C1 ≈ +0.031; C3 +0.017; C4 +0.011; C2 là ngoại lệ (+0.011)	Ổn định
H3. FedAvg ≈ Centralized	Không khác biệt ở cả 5 client	Trung bình −0.0012, dấu thay đổi giữa các seed; riêng C2 thấp hơn ở 3/3 seed (−0.0090)	Ổn định, trừ C2
H4. Personalized FL > FedAvg	Ditto +0.008 ở C2, gần có ý nghĩa	Ditto +0.0063 ở C2 (3/3) nhưng −0.0035 ở C4 (0/3); trung bình −0.0017	Đánh đổi: có lợi cho client nhỏ, đặc thù; bất lợi cho client lớn
H5. Kết luận ổn định qua seed	Chưa kiểm định	Đã lặp 3 seed huấn luyện	H1–H3 ổn định; H4 chỉ đúng ở C2

C2 là client duy nhất mà FedAvg thấp hơn Centralized ở mọi seed. Ditto thu hẹp phần lớn khoảng cách này (còn −0.0027 so với Centralized), phù hợp với nhận định rằng cá nhân hóa có ích cho client nhỏ và lệch phân phối mạnh. Tuy nhiên 3 seed chỉ cho thấy chênh lệch nhất quán

về dấu; mức tăng của Ditto ở C2 (+0.0063) vẫn xấp xỉ độ lệch chuẩn (0.0043), nên chưa đủ để khẳng định có ý nghĩa thống kê.

6. Hạn chế và hướng cải thiện

Hạn chế lớn nhất là kịch bản chia theo vùng gần như không tạo concept shift, nên Personalized FL chưa có điều kiện để vượt FedAvg.

Bảng 6. Các hạn chế của cách chia dữ liệu và hướng cải thiện

Hạn chế	Bằng chứng	Hướng cải thiện
Các tổ chức chỉ khác nhau về quy mô và lệch nhẹ về đặc trưng, không khác về quan hệ rủi ro	Kiểm định calibration theo client: LRT intercept p = 0.86, slope p = 0.70. Thêm CLIENT_ID vào LightGBM không tăng AUC có ý nghĩa. Qua 3 seed, FedAvg chỉ thấp hơn Centralized trung bình 0.0012 AUC	Chạy Personalized FL trên label_dirichlet_a0.5 và income_mix_a0.5; quét $\alpha \in \{0.1, 1, 5\}$ để đánh giá lợi ích của Personalized FL theo mức non-IID
Dùng REGION_POPULATION_RELATIVE làm mã vùng là suy luận	Dữ liệu đã ẩn danh; hai vùng trùng mật độ dân số sẽ bị gộp làm một	Ghi rõ là giả định; kiểm tra độ nhạy với một cách chia khác
Địa bàn độc quyền, mỗi khách hàng chỉ thuộc một tổ chức	Thực tế ngân hàng lớn hoạt động toàn quốc và một khách hàng có thể vay ở nhiều nơi	Trường hợp khách hàng trùng giữa các bên là bài toán vertical FL, đưa vào hướng phát triển
Mọi tổ chức có chung schema, sản phẩm và cách tính EXT_SOURCE	Ngoài thực tế các ngân hàng hiếm khi đồng nhất như vậy	Nêu trong phần giả định; thử bỏ hoặc làm nhiễu một số đặc trưng ở một vài client
Mới lặp 3 seed huấn luyện (chỉ Centralized HeteroGNN, Local-only, FedAvg, Ditto) và 1 lần lấy mẫu phân vùng	Mức tăng của Ditto ở C2 (+0.0063 ± 0.0043) xấp xỉ độ lệch chuẩn; chưa biết kết luận có giữ được khi các vùng rơi vào tổ chức khác	Tăng lên 5 seed và thêm FedPer, FedProx, Fine-tune; lặp lại bước chia client với nhiều seed
Client nhỏ có tập Validation quá ít mẫu	C2 chỉ có 1,452 khách hàng Test; fine-tune ở C0 tăng AUC Validation nhưng giảm AUC Test	Chọn checkpoint theo Validation gộp hoặc dùng cross-validation trong client

7. Kết luận

Chia theo địa bàn vùng tạo ra kịch bản Federated Learning sát thực tế: lệch quy mô theo Dirichlet, lệch đặc trưng tự nhiên theo vùng và lệch nhãn rất nhẹ, không dùng TARGET khi chia. Trong kịch bản này, các tổ chức không khác nhau về quan hệ giữa đặc trưng và rủi ro, nên FedAvg đã đủ cho phần lớn tổ chức. Kết quả lặp lại qua 3 seed huấn luyện xác nhận FedAvg tốt hơn Local-only ở mọi client và gần bằng Centralized; Ditto chỉ có lợi ổn định ở tổ chức nhỏ và đặc thù nhất (C2), đổi lại giảm nhẹ ở tổ chức lớn nhất (C4). Các kịch bản label_dirichlet_a0.5 và income_mix_a0.5 sẽ được dùng để xác định khi nào Personalized FL bắt đầu có ích.