

KHÓA LUẬN TỐT NGHIỆP

Personalized Federated Heterogeneous Graph Learning for Credit Risk Prediction

BÁO CÁO TIẾN ĐỘ: DỮ LIỆU, PIPELINE, BASELINE VÀ PERSONALIZED FL

Bộ dữ liệu: Home Credit Default Risk (Kaggle)

Người thực hiện: Anh Thu

Ngày cập nhật: 02/10/2026

Mã nguồn: nhánh git feat/centralized-baselines (repo home_credit_fedheterognn)

1. Tổng quan

Mục tiêu của đề tài là dự đoán khả năng vỡ nợ ($TARGET = 1$) của khách hàng vay tiêu dùng, khai thác cấu trúc quan hệ của dữ liệu tín dụng dưới dạng heterogeneous graph, và huấn luyện theo hướng federated để các tổ chức không phải chia sẻ dữ liệu khách hàng thô. Báo cáo này tổng hợp các quyết định thiết kế, code đã cài đặt và kết quả thực nghiệm đạt được tới thời điểm hiện tại.

Tình trạng hiện tại:

- Hoàn thành: tiền xử lý, split chung, 3 baseline Centralized (Logistic Regression, LightGBM, HeteroGNN), dựng heterogeneous graph kèm xử lý orphan records, nhánh Federated với 5 client (Local-only, FedAvg), 4 phương pháp Personalized FL (FedAvg + Fine-tune, FedProx, FedPer, Ditto), đánh giá theo từng client có khoảng tin cậy bootstrap.
- Chưa thực hiện: Personalized FL trên kịch bản non-IID mạnh, tune siêu tham số, lặp lại nhiều seed và quét mức non-IID (α).

Các kết luận chính

- Centralized LightGBM mạnh nhất: ROC-AUC trên Test chung 0.7931.
- Centralized HeteroGNN (0.7858) tốt hơn Logistic Regression (0.7832) dù node khách hàng chỉ dùng đặc trưng application.
- Trong kịch bản chia theo địa bàn vùng, FedAvg HeteroGNN đạt AUC trung bình theo client 0.7833, cao hơn Local-only (0.7678) có ý nghĩa thống kê ở 4/5 client và không khác biệt có ý nghĩa so với Centralized HeteroGNN ở cả 5 client.
- Trong kịch bản chính, chưa phương pháp Personalized FL nào tốt hơn FedAvg có ý nghĩa thống kê. Ditto cải thiện client nhỏ và đặc thù nhất (C2) từ 0.7789 lên 0.7871 (gần có ý nghĩa) và có AUC client kém nhất cao nhất nhóm Federated.
- FedAvg đã gần chạm cận trên Centralized nên còn ít chỗ để cá nhân hóa cải thiện; cần kiểm chứng trên kịch bản non-IID mạnh hơn.

2. Dữ liệu và các quyết định ban đầu

2.1. Các bảng dữ liệu

Bảng 1. Các bảng của Home Credit Default Risk

Bảng	Khóa	Vai trò
application_train	SK_ID_CURR	Hồ sơ vay hiện tại, có TARGET (307,511 dòng, default 8.07%)
application_test	SK_ID_CURR	Không có TARGET (48,744 dòng), chỉ dùng nộp Kaggle
bureau / bureau_balance	SK_ID_BUREAU	Lịch sử tín dụng bên ngoài và trạng thái theo tháng
previous_application	SK_ID_PREV	Hồ sơ vay trước đây tại Home Credit
installments_payments	SK_ID_PREV	Từng kỳ trả góp
POS_CASH_balance	SK_ID_PREV	Bản ghi POS/cash theo tháng
credit_card_balance	SK_ID_PREV	Bản ghi thẻ tín dụng theo tháng

2.2. Quyết định về tập đánh giá

Kiểm tra dữ liệu cho thấy application_test.csv không có cột TARGET, nên không thể dùng để tính metric. Vì vậy mọi tập có nhãn (Train/Validation/Test) đều được tách từ application_train. Split được tạo một lần (70/15/15, stratified theo TARGET, seed 42) và dùng chung cho cả hai nhánh. Bước chia client giữ nguyên cột split, nên hợp các tập Test của client đúng bằng tập Test chung. Nhờ đó Centralized và Federated được so sánh trên cùng dữ liệu.


Bảng 2. Split chung

Tập	Số khách hàng	Tỷ lệ default
Train	215,257	8.07%
Validation	46,127	8.07%
Test	46,127	8.07%

2.3. Kiểm soát rò rỉ dữ liệu (leakage)

- Mọi encoder (clip quantile, impute median, chuẩn hóa, one-hot, danh mục category) chỉ fit trên Train.
- Validation chỉ dùng để chọn siêu tham số, early stopping, checkpoint và threshold; Test chỉ dùng đánh giá một lần.
- Các aggregate từ bảng lịch sử chỉ dùng dữ liệu của chính khách hàng, không dùng nhãn.
- Mỗi bản ghi lịch sử (bureau, previous, installments, POS, credit card) chỉ thuộc về đúng một khách hàng, nên graph gồm nhiều cây tách rời: mỗi khách hàng là gốc của một cây và không có cạnh nào nối giữa các khách hàng. Khi huấn luyện, mô hình chỉ truyền thông tin bên trong cây của từng khách hàng Train, nên không thể nhận thông tin từ khách hàng Validation hoặc Test qua cấu trúc graph. Mặt trái là GNN ở đây học cách tổng hợp lịch sử tín dụng của từng khách hàng, không khai thác quan hệ giữa các khách hàng với nhau.

3. Pipeline tổng thể



Hình 1. Pipeline của đề tài. Màu xanh lam là nhánh Centralized, màu xanh lục là nhánh Federated. Centralized chỉ chia Train/Val/Test 70/15/15, không chia client, và được đánh giá trên toàn bộ Test. Khi so sánh với Federated, cùng các dự đoán Test đó được nhóm theo client của khách hàng; việc nhóm này chỉ diễn ra ở bước chấm điểm, không ảnh hưởng tới cách huấn luyện.

4. Nhánh Centralized: baseline tabular

4.1. Tiền xử lý và đặc trưng

- Làm sạch: DAYS_EMPLOYED = 365243 (giá trị giữ chỗ) thành NaN kèm cờ; CODE_GENDER = XNA, ORGANIZATION_TYPE = XNA thành NaN; các cột DAYS_* = 365243 trong previous_application thành NaN.
- Đặc trưng tỷ lệ: CREDIT/INCOME, ANNUITY/INCOME, PAYMENT_RATE, GOODS/CREDIT, EXT_SOURCE mean/std/min/prod...

- Aggregate theo SK_ID_CURR từ 6 bảng phụ (bureau + bureau_balance, previous, installments, POS, credit card), kèm thống kê riêng cho khoản Active/Closed và Approved/Refused. Tổng cộng 601 đặc trưng.

4.2. Cấu hình mô hình

- Logistic Regression: clip quantile 1%/99%, impute median kèm cờ missing, chuẩn hóa, one-hot (1231 cột sau mã hóa). C chọn trên Validation trong {0.001, 0.01, 0.1}; C tốt nhất = 0.01.
- LightGBM: learning rate 0.02, num_leaves 34, max_depth 8, colsample 0.3, subsample 0.87; early stopping 200 vòng theo AUC Validation; số cây tốt nhất = 1488.
- Threshold chọn trên Validation theo tiêu chí F1 cao nhất.

5. Heterogeneous graph

5.1. Schema

Bảng 3. Node type của graph toàn cục

Node type	Định danh	Số node	Số đặc trưng	Ý nghĩa
customer	SK_ID_CURR	307,511	300	Hồ sơ vay hiện tại (chỉ đặc trưng application)
bureau	SK_ID_BUREAU	1,465,325	61	Tín dụng bên ngoài; bureau_balance gộp thành đặc trưng
prev	SK_ID_PREV	1,453,595	168	Hồ sơ vay trước (gồm node placeholder)
installment	event-level	11,591,592	17	Kỳ trả góp
pos	monthly record	8,543,375	11	Bản ghi POS/cash theo tháng
cc	monthly record	3,227,965	36	Bản ghi thẻ tín dụng theo tháng

Cạnh có hướng theo khóa ngoại: customer → bureau, customer → prev, prev → installment, prev → pos, prev → cc; mỗi cạnh có cạnh ngược (rev_*) để message passing hai chiều, tổng cộng 10 edge type. Sau khi dựng, script kiểm tra chỉ số cạnh hợp lệ, mỗi node con có đúng một node cha, và cạnh ngược khớp cạnh xuôi.

5.2. Orphan records và cách xử lý

Bảng 4. Orphan records trong graph toàn cục

Trường hợp	Số liệu	Cách xử lý
A. Event trở tới SK_ID_PREV không có trong previous_application	installment 8.8%, POS 3.4%, credit card 27.0% số dòng	Tạo 39,894 node prev placeholder (IS_PLACEHOLDER = 1, cờ PH_FROM_*)
B. SK_ID_CURR của event khác của prev cha	0 dòng	Có kiểm tra; nếu có thì bỏ event
C1. Prev không có lịch sử trả	565,528 prev (Refused/Canceled 0% có lịch sử; 37,926 khoản Approved)	Không phải lỗi; giữ node, thêm đặc trưng cấu trúc N_* và HAS_*
C2. Customer không có lịch sử	không bureau 44,020; không prev 14,697; không cả hai 2,200	Giữ node; mô hình dùng đặc trưng của chính node qua nhánh residual
D. bureau_balance không trở tới bureau nào	3,120,184 dòng	Không nối được về khách hàng nên bỏ; bureau thiếu bureau_balance được đánh cờ

5.3. Centralized HeteroGNN

- Encoder tuyến tính riêng cho từng node type, sau đó 2 tầng HeteroConv với SAGEConv (mean) cho từng edge type, residual + LayerNorm, hidden 64, dropout 0.2; tầng cuối chỉ tính các cạnh đi vào customer; MLP phân loại.
- AdamW (lr 0.001), batch 1,024 khách hàng (lấy trọn cây con), early stopping theo AUC Validation; epoch tốt nhất = 6, thời gian 316 giây trên CPU.

5.4. Kết quả Centralized trên Test chung

Bảng 5. Kết quả Centralized trên Test chung (46,127 khách hàng)

Mô hình	ROC-AUC	PR-AUC	KS	Brier	F1	Precision	Recall	Threshold
Logistic Regression	0.7832	0.2775	0.4317	0.0661	0.3376	0.2724	0.4436	0.162
LightGBM	0.7931	0.2951	0.4448	0.0653	0.3495	0.2965	0.4256	0.173
HeteroGNN	0.7858	0.2819	0.4365	0.0659	0.3370	0.2742	0.4372	0.177

Bảng 6. Kết quả Centralized trên Validation

Mô hình	ROC-AUC	PR-AUC	KS	F1
Logistic Regression	0.7802	0.2743	0.4189	0.3309
LightGBM	0.7919	0.2942	0.4411	0.3459
HeteroGNN	0.7834	0.2814	0.4264	0.3380

Bảng 7. Ma trận nhầm lẫn trên Test (3,724 ca default)

Mô hình	TP	FP	TN	FN
Logistic Regression	1,652	4,412	37,991	2,072
LightGBM	1,585	3,760	38,643	2,139
HeteroGNN	1,628	4,309	38,094	2,096

AUC trên Validation và Test chênh nhau dưới 0.003 ở cả 3 mô hình, nên không có dấu hiệu overfit hay leakage. Các đặc trưng quan trọng nhất của LightGBM: EXT_SOURCE_MEAN, EXT_SOURCE_MIN, ORGANIZATION_TYPE, EXT_SOURCE_3, EXT_SOURCE_PROD, EXT_SOURCE_2, PAYMENT_RATE, GOODS_CREDIT_RATIO.

6. Nhánh Federated

6.1. Bối cảnh nghiệp vụ

Kịch bản là Horizontal Federated Learning giữa các tổ chức hoặc đơn vị cho vay theo vùng. Mỗi tổ chức phục vụ khách hàng trên địa bàn của mình, có cùng schema dữ liệu và không được gom dữ liệu khách hàng về một chỗ do quy định bảo mật thông tin khách hàng (có thể tham chiếu Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân và quy định bảo mật thông tin khách hàng trong Luật Các tổ chức tín dụng 2024; cần kiểm tra điều khoản cụ thể trước khi trích dẫn). Đây là mô phỏng vì Home Credit là một tổ chức duy nhất, nhưng mô phỏng dựa trên thuộc tính có thật của dữ liệu.

Bảng chứng từ dữ liệu: REGION_POPULATION_RELATIVE (dân số chuẩn hóa của vùng nơi khách hàng sinh sống) chỉ có 81 giá trị khác nhau và mỗi giá trị ứng với đúng một REGION_RATING_CLIENT (100% trường hợp), nên được dùng làm mã vùng. Đây là suy luận từ dữ liệu đã ẩn danh và được ghi rõ là giả định. 81 vùng là đơn vị địa lý; client là 5 tổ chức, mỗi tổ chức phụ trách một nhóm vùng.

6.2. Quy tắc sở hữu client

Bảng 8. Quy tắc sở hữu client

Quy tắc	Nội dung
R1	Mỗi khách hàng (SK_ID_CURR) thuộc đúng một client
R2	Khách hàng thuộc tổ chức phụ trách vùng nơi họ sinh sống (REGION_POPULATION_RELATIVE)
R3	Mỗi vùng do đúng một tổ chức phụ trách; Dirichlet chỉ quyết định quy mô tổ chức
R4	Toàn bộ lịch sử của khách hàng (bureau, previous, installments, POS, credit card) đi theo client sở hữu
R5	Nhân, split và dữ liệu thô ở lại client; chỉ trao đổi trọng số mô hình và thống kê tổng hợp

6.3. Lựa chọn cách chia client

Bảng 9. So sánh các cách chia client

Cách chia	Quy mô client	Tỷ lệ default	Đánh giá
Dirichlet theo nhân ($\alpha = 0.5$)	2.5% – 78%	3.1% – 72%	Phi thực tế (dùng TARGET khi chia); giữ làm stress test
P1: theo hạng vùng	10% – 25%	4.8% – 11.1%	Dễ giải thích nhưng các client đều lớn
P2: thị phần mỗi vùng $\sim$ Dir(0.5)	14% – 26%	7.8% – 8.4%	Loại: gần như IID
P3: địa bàn độc quyền, quy mô $\sim$ Dir(0.5)	3.2% – 47.4%	7.6% – 9.3%	Kịch bản chính

Cách chia P3 trả lời hai câu hỏi khác nhau. Vùng sinh sống quyết định khách hàng thuộc tổ chức nào; Dirichlet quyết định mỗi tổ chức lớn bao nhiêu. Cụ thể:

- **Bước 1, quy mô:** lấy mẫu $q \sim \text{Dirichlet}(\alpha = 0.5)$ cho 5 tổ chức, tổng các tỷ lệ bằng 1. Lần lấy mẫu được chấp nhận cho $q = [10.8\%, 9.4\%, 4.5\%, 27.4\%, 47.9\%]$. α càng nhỏ thì quy mô các tổ chức càng chênh lệch; α rất lớn thì các tổ chức gần bằng nhau.
- **Bước 2, địa bàn:** xếp 81 vùng theo thứ tự ngẫu nhiên, lần lượt giao từng vùng cho tổ chức đang thiếu khách hàng nhiều nhất so với quy mô mục tiêu. Mỗi vùng được giao nguyên vẹn, nên quy mô thực tế chỉ xấp xỉ q .
- **Bước 3, khách hàng:** khách hàng sống ở vùng nào thuộc tổ chức phụ trách vùng đó, kéo theo toàn bộ lịch sử tín dụng.

Bảng 10. Quy mô mục tiêu theo Dirichlet và quy mô thực tế sau khi gán vùng

Client	Quy mô mục tiêu q	Quy mô thực tế	Số vùng
C0	10.8%	11.3%	10
C1	9.4%	8.4%	5
C2	4.5%	3.2%	3
C3	27.4%	29.6%	23
C4	47.9%	47.4%	40

6.4. Cơ sở lý thuyết của cách chia

Các tài liệu về Federated Learning phân dữ liệu non-IID thành ba loại chính (Kairouz et al., 2021, Advances and Open Problems in Federated Learning; Li et al., 2022, Federated Learning on Non-IID Data Silos: An Experimental Study, ICDE):

Bảng 11. Đối chiếu cách chia với phân loại non-IID

Loại non-IID	Cách mô phỏng phổ biến	Trong đề tài
Quantity skew (lệch số lượng)	Li et al. (2022): $q \sim \text{Dir}(\beta)$, giao cho client j tỷ lệ q_j dữ liệu	Đúng cách này: $q \sim \text{Dirichlet}(0.5)$
Feature skew (lệch đặc trưng)	Chia theo thuộc tính tự nhiên của dữ liệu (natural partition, ví dụ bộ LEAF chia theo người viết)	Chia theo vùng: mỗi tổ chức có tổ hợp vùng khác nhau nên thu nhập, EXT_SOURCE khác nhau
Label skew (lệch nhãn)	Hsu et al. (2019): Dirichlet trên nhãn	Không cố tình tạo; xuất hiện tự nhiên ở mức nhẹ (default 7.6% – 9.3%)

Như vậy cách chia là quantity skew theo Dirichlet kết hợp feature skew tự nhiên theo vùng. Cách chia Dirichlet theo nhãn (Hsu et al., 2019) phổ biến cho phân loại ảnh nhưng không hợp với tín dụng, vì tổ chức không thể phân khách hàng theo kết quả vỡ nợ; vì vậy nó chỉ được giữ làm stress test. Hai điểm khác với công thức chuẩn:

- **Gán theo vùng:** Gán nguyên vùng thay vì gán từng mẫu (do quy tắc R3), nên quy mô thực tế chỉ xấp xỉ q .
- **Loại bỏ mẫu không đạt ràng buộc:** lần lấy mẫu bị loại nếu có client dưới 3% khách hàng hoặc dưới 30 mẫu mỗi lớp ở Train/Val/Test (kịch bản chính được chấp nhận ở lần thứ 2). Ràng buộc này bảo đảm mỗi client đủ dữ liệu để train và đánh giá, nhưng làm phân phối quy mô lệch nhẹ so với Dirichlet thuần.

6.5. Đặc điểm các client

Bảng 12. Đặc điểm client trong kịch bản chính region_territory_a0.5

Client	Khách hàng	Tỷ trọng	Default	Số vùng	Vùng hạng 1	Vùng hạng 3	W(EXT_SOURCE_2)	Train / Val / Test
C0	34,805	11.3%	7.6%	10	1.8%	6.4%	0.110	24,443 / 5,101 / 5,261
C1	25,860	8.4%	8.5%	5	0.0%	13.3%	0.047	18,050 / 4,025 / 3,785
C2	9,866	3.2%	9.2%	3	0.0%	0.0%	0.195	6,875 / 1,539 / 1,452
C3	91,159	29.6%	8.2%	23	9.2%	21.4%	0.016	63,733 / 13,700 / 13,726
C4	145,821	47.4%	8.0%	40	15.9%	15.9%	0.011	102,156 / 21,762 / 21,903

$W(\text{EXT_SOURCE_2})$ là khoảng cách Wasserstein giữa phân phối EXT_SOURCE_2 của client và toàn cục, chuẩn hóa theo độ lệch chuẩn toàn cục; giá trị lớn nghĩa là lệch phân phối đặc trưng mạnh.

6.6. Local graph và encoder thống nhất

- Mỗi client tự xử lý orphan, nối cạnh và tính đặc trưng cấu trúc trên dữ liệu của mình. Tổng số placeholder của 5 client bằng đúng số placeholder của graph toàn cục.
- Encoder thống nhất qua 2 vòng trao đổi thống kê tổng hợp trên Train của client: vòng 1 gửi quantile, median, cờ có-missing và tần suất category; vòng 2 gửi n , tổng và tổng bình phương để server tính mean/std toàn cục. Mọi client có cùng số chiều đặc trưng (customer 313, bureau 64, prev 173, installment 17, pos 12, cc 37), điều kiện để FedAvg gộp trọng số.

6.7. Huấn luyện các baseline Federated

- Kiến trúc và optimizer giống Centralized HeteroGNN; cùng khởi tạo cho mọi phương pháp.
- Local-only: mỗi client train riêng tối đa 30 epoch, early stopping 4 epoch theo AUC Validation của client; optimizer giữ trạng thái suốt quá trình train.
- FedAvg: tối đa 40 round, 1 epoch cục bộ mỗi round, server lấy trung bình trọng số theo số mẫu Train; checkpoint chọn theo AUC Validation trung bình có trọng số; round tốt nhất = 15.
- Threshold của từng client chọn trên Validation của client đó (max F1).

6.8. Personalized Federated Learning

Bốn phương pháp cá nhân hóa được cài đặt trên cùng kiến trúc HeteroGNN, cùng kịch bản chia và cùng quy trình chọn checkpoint (AUC Validation trung bình có trọng số của mô hình mà mỗi client thực sự dùng để dự đoán):

Bảng 13. Các phương pháp Personalized FL

Phương pháp	Phần được cá nhân hóa	Cơ chế	Siêu tham số
FedAvg + Fine-tune	Toàn bộ mô hình, sau khi FedAvg hội tụ	Mỗi client train thêm trên dữ liệu của mình; mô hình FedAvg ban đầu cũng là ứng viên (epoch 0)	lr 0.0005, tối đa 10 epoch, patience 2
FedProx (Li et al., 2020)	Không cá nhân hóa; ổn định hóa khi non-IID	Thêm số hạng phạt $\mu/2\ w - w_{\text{global}}\ ^2$ khi train cục bộ	$\mu = 0.01$
FedPer (Arivazhagan et al., 2019)	Head phân loại	Encoder và các tầng GNN được chia sẻ qua FedAvg; head ở lại từng client	head = MLP sau GNN
Ditto (Li et al., 2021)	Toàn bộ mô hình riêng của client	Ngoài mô hình chung, mỗi client giữ mô hình riêng v , train với phạt $\lambda/2\ v - w_{\text{global}}\ ^2$	$\lambda = 0.1$

7. Kết quả

Phần 5.4 là kết quả chính của các baseline Centralized trên toàn bộ Test. Phần này so sánh mọi mô hình trên Test của từng client trong nhánh Federated.

Cách đọc các dòng Centralized: mỗi mô hình Centralized được huấn luyện một lần trên toàn bộ Train (70/15/15, không chia client). Các cột "KH Test của Ck" là AUC của cùng mô hình đó tính trên nhóm khách hàng Test thuộc client k ; mô hình không được huấn luyện theo client. Đây là cận trên khi dữ liệu được gom về một chỗ, dùng để so sánh công bằng trên đúng nhóm khách hàng mà mô hình Federated của client k được đánh giá.

7.1. Kịch bản chính: region_territory_a0.5

Bảng 14. ROC-AUC trên Test của từng client

Nhóm	Mô hình	KH Test của C0	KH Test của C1	KH Test của C2	KH Test của C3	KH Test của C4	Trung bình	Kém nhất
Cận trên (Centralized)	Logistic Regression	0.7827	0.7719	0.7889	0.7845	0.7835	0.7829	0.7719
Cận trên (Centralized)	LightGBM	0.7898	0.7834	0.7879	0.7946	0.7945	0.7928	0.7834
Cận trên (Centralized)	HeteroGNN	0.7830	0.7752	0.7869	0.7875	0.7869	0.7856	0.7752
FL baseline	Local-only	0.7491	0.7463	0.7701	0.7718	0.7733	0.7678	0.7463
FL baseline	FedAvg	0.7775	0.7731	0.7789	0.7881	0.7838	0.7833	0.7731
Personalized FL	FedAvg + Fine-tune	0.7731	0.7752	0.7789	0.7881	0.7838	0.7830	0.7731
Personalized FL	FedProx	0.7739	0.7671	0.7839	0.7822	0.7802	0.7791	0.7671
Personalized FL	FedPer	0.7754	0.7732	0.7830	0.7878	0.7823	0.7824	0.7732
Personalized FL	Ditto	0.7794	0.7747	0.7871	0.7868	0.7807	0.7821	0.7747

"Trung bình" có trọng số theo số khách hàng Test của từng client; "Kém nhất" là AUC thấp nhất trong 5 client.

Bảng 15. PR-AUC trên Test của từng client

Nhóm	Mô hình	KH Test của C0	KH Test của C1	KH Test của C2	KH Test của C3	KH Test của C4
Cận trên (Centralized)	Logistic Regression	0.2605	0.2647	0.2783	0.2906	0.2771
Cận trên (Centralized)	LightGBM	0.2730	0.2922	0.3013	0.3059	0.2955
Cận trên (Centralized)	HeteroGNN	0.2610	0.2660	0.3087	0.2900	0.2845
FL baseline	Local-only	0.2094	0.2383	0.2520	0.2634	0.2609
FL baseline	FedAvg	0.2598	0.2579	0.2972	0.2790	0.2822
Personalized FL	FedAvg + Fine-tune	0.2592	0.2579	0.2972	0.2790	0.2822
Personalized FL	FedProx	0.2536	0.2412	0.2755	0.2790	0.2762
Personalized FL	FedPer	0.2481	0.2605	0.2830	0.2797	0.2780
Personalized FL	Ditto	0.2609	0.2531	0.2929	0.2814	0.2788

Bảng 16. F1 trên Test của từng client (Centralized dùng threshold chung chọn trên Val chung, Federated dùng threshold của từng client chọn trên Val của client)

Nhóm	Mô hình	KH Test của C0	KH Test của C1	KH Test của C2	KH Test của C3	KH Test của C4
Cận trên (Centralized)	Logistic Regression	0.3264	0.3373	0.3551	0.3477	0.3319
Cận trên (Centralized)	LightGBM	0.3307	0.3756	0.3557	0.3641	0.3384
Cận trên (Centralized)	HeteroGNN	0.3116	0.3514	0.3443	0.3390	0.3377
FL baseline	Local-only	0.2866	0.3066	0.3160	0.3184	0.3192
FL baseline	FedAvg	0.3184	0.3539	0.3561	0.3398	0.3348
Personalized FL	FedAvg + Fine-tune	0.3275	0.3463	0.3561	0.3398	0.3348
Personalized FL	FedProx	0.3189	0.3383	0.3022	0.3369	0.3280
Personalized FL	FedPer	0.3149	0.3480	0.3383	0.3422	0.3267
Personalized FL	Ditto	0.3065	0.3429	0.3478	0.3410	0.3257

Bảng 17. Chênh lệch ROC-AUC của các baseline Federated, kèm khoảng tin cậy 95% (paired bootstrap, 1,000 lần)

So sánh	C0	C1	C2	C3	C4
FedAvg – Local-only	+0.028 * [+0.012, +0.045]	+0.027 * [+0.012, +0.043]	+0.009 [-0.020, +0.037]	+0.016 * [+0.010, +0.023]	+0.011 * [+0.006, +0.015]
FedAvg – Centralized HeteroGNN	-0.005 [-0.015, +0.003]	-0.002 [-0.010, +0.007]	-0.008 [-0.021, +0.004]	+0.001 [-0.004, +0.005]	-0.003 [-0.007, +0.001]
Local-only – Centralized HeteroGNN	-0.034 * [-0.049, -0.017]	-0.029 * [-0.043, -0.013]	-0.017 [-0.048, +0.013]	-0.016 * [-0.022, -0.009]	-0.014 * [-0.018, -0.009]

Bảng 18. Chênh lệch ROC-AUC của Personalized FL so với FedAvg, kèm khoảng tin cậy 95%

So sánh	C0	C1	C2	C3	C4
FedAvg + Fine-tune – FedAvg	-0.004 [-0.010, +0.001]	+0.002 [-0.004, +0.007]	+0.000 [+0.000, +0.000]	+0.000 [+0.000, +0.000]	+0.000 [+0.000, +0.000]
FedProx – FedAvg	-0.004 [-0.012, +0.005]	-0.006 [-0.015, +0.003]	+0.005 [-0.009, +0.019]	-0.006 * [-0.011, -0.001]	-0.004 [-0.008, +0.001]
FedPer – FedAvg	-0.002 [-0.008, +0.004]	+0.000 [-0.006, +0.005]	+0.004 [-0.005, +0.013]	-0.000 [-0.004, +0.003]	-0.001 [-0.004, +0.001]
Ditto – FedAvg	+0.002 [-0.004, +0.008]	+0.002 [-0.004, +0.007]	+0.008 [-0.002, +0.019]	-0.001 [-0.005, +0.003]	-0.003 * [-0.006, -0.000]
Ditto – Centralized HeteroGNN	-0.004 [-0.012, +0.006]	-0.000 [-0.008, +0.008]	+0.000 [-0.012, +0.014]	-0.001 [-0.006, +0.004]	-0.006 * [-0.010, -0.002]

Dấu * đánh dấu chênh lệch có ý nghĩa thống kê (khoảng tin cậy không chứa 0). Fine-tune bằng 0 ở các client giữ nguyên mô hình FedAvg (epoch tốt nhất = 0).

Bảng 19. Cấu hình và thời gian huấn luyện các phương pháp Federated (CPU 16 luồng)

Phương pháp	Cấu hình	Checkpoint tốt nhất	Thời gian (giây)
Local-only	tối đa 30 epoch, patience 4	epoch 8, 8, 13, 6, 5	662
FedAvg	1 epoch cục bộ / round	round 15/21	880
FedAvg + Fine-tune	lr 0.0005, tối đa 10 epoch	epoch 1, 3, 0, 0, 0 (0 = giữ FedAvg)	158
FedProx	$\mu = 0.01$	round 30/36	2,560
FedPer	head riêng ở client	round 17/23	1,515
Ditto	$\lambda = 0.1$	round 15/21	5,158

7.2. Stress test: label_dirichlet_a0.5

Bảng 20. Đặc điểm client khi chia Dirichlet theo nhãn

Client	Khách hàng	Tỷ trọng	Default
C0	15,514	5.1%	4.8%
C1	239,550	77.9%	3.1%
C2	21,033	6.8%	72.1%
C3	7,626	2.5%	10.2%
C4	23,788	7.7%	3.4%

Bảng 21. ROC-AUC trên Test của từng client (stress test, chỉ các baseline)

Nhóm	Mô hình	KH Test của C0	KH Test của C1	KH Test của C2	KH Test của C3	KH Test của C4	Trung bình	Kém nhất
Cận trên (Centralized)	Logistic Regression	0.7689	0.7835	0.7924	0.7824	0.7971	0.7843	0.7689
Cận trên (Centralized)	LightGBM	0.7728	0.7910	0.8022	0.8024	0.8102	0.7926	0.7728
Cận trên (Centralized)	HeteroGNN	0.7701	0.7852	0.8002	0.7859	0.8032	0.7868	0.7701
FL baseline	Local-only	0.7074	0.7665	0.7669	0.7131	0.7708	0.7625	0.7074
FL baseline	FedAvg	0.7613	0.7692	0.7853	0.7618	0.7842	0.7708	0.7613

Stress test mới chạy các baseline, chưa chạy Personalized FL; kết quả Local-only ở đây là từ trước khi sửa optimizer.

Lưu ý về metric gộp: trong stress test, AUC gộp của Local-only lên tới 0.8972 và F1 gộp của Federated khoảng 0.5731. Đây là con số ảo: mô hình riêng học theo tỷ lệ nền của từng client (một client có 72% default), và threshold riêng theo client khai thác chênh lệch này. Vì vậy báo cáo dùng AUC theo từng client, AUC trung bình và AUC của client kém nhất, không dùng AUC/F1 gộp.

8. Thảo luận

Bảng 22. Kiểm định các giả thuyết

Giả thuyết	Kết quả (kịch bản chính)
H1. Hợp tác có lợi: FedAvg > Local-only	Đúng ở 4/5 client (+0.011 đến +0.028, có ý nghĩa thống kê); client kém nhất tăng 0.7463 → 0.7731
H2. Lợi ích lớn hơn ở tổ chức nhỏ	Mức tăng giảm theo quy mô: C0, C1 $\approx$ +0.028; C3 +0.016; C4 (lớn nhất) +0.011; ngoại lệ C2
H3. Chi phí bảo mật nhỏ: FedAvg $\approx$ Centralized	Không khác biệt có ý nghĩa so với Centralized HeteroGNN ở cả 5 client
H4. Personalized FL > FedAvg	Chưa đạt: không phương pháp nào tốt hơn FedAvg có ý nghĩa thống kê. Ditto tăng ở C2 (+0.008, gần có ý nghĩa) và có AUC client kém nhất cao nhất nhóm Federated, nhưng giảm nhẹ ở C4; FedProx kém hơn FedAvg
H5. Kết luận ổn định	Chưa kiểm định: mới có 1 seed

C2 là client nhỏ nhất (3.2%), chỉ có 3 vùng, không có vùng hạng 1 hay hạng 3, và lệch phân phối EXT_SOURCE_2 mạnh nhất. FedAvg không cải thiện rõ C2 so với Local-only (khoảng tin cậy chứa 0). Ditto nâng C2 lên 0.7871, ngang Centralized HeteroGNN (0.7869), phù hợp với kỳ vọng rằng cá nhân hóa giúp client đặc thù.

Cá nhân hóa chưa tạo khác biệt lớn vì trong kịch bản này FedAvg đã gần như chạm cận trên Centralized (khoảng cách tối đa khoảng 0.008 AUC ở C2), nên còn rất ít chỗ để cải thiện. Dữ liệu chủ yếu lệch về số lượng, lệch đặc trưng ở mức vừa và lệch nhãn rất nhẹ; cá nhân hóa thường có lợi rõ khi các client khác nhau nhiều về phân phối. Kết luận rút ra là hiệu quả của Personalized FL phụ thuộc vào mức độ non-IID, và cần kiểm chứng thêm trên kịch bản non-IID mạnh.

Fine-tune ở C0 làm AUC Validation tăng nhưng AUC Test giảm (-0.004), dấu hiệu overfit vào tập Validation nhỏ của client.

9. Hạn chế và hướng tiếp theo

- **Kịch bản non-IID mạnh:** chạy 4 phương pháp Personalized FL trên stress test label_dirichlet_a0.5, nơi FedAvg thua Centralized trung bình khoảng 0.016 AUC.
- **Tune siêu tham số trên Validation:** λ của Ditto $\in \{0.01, 0.1, 1\}$, μ của FedProx $\in \{0.001, 0.01\}$.
- **Nhiều seed:** lặp lại 3 seed cho FedAvg và Ditto để kiểm tra mức cải thiện ở C2 có ổn định không.
- **Quét mức non-IID:** thêm kịch bản $\alpha \in \{0.1, 1, 5\}$ để vẽ lợi ích của Personalized FL theo mức non-IID.
- **HeteroGNN:** chưa tune (attention khi gộp event, mã hóa thời gian, pos_weight, hidden lớn hơn).
- **Hạ tầng:** Ditto mất khoảng 86 phút trên CPU; cần lưu checkpoint theo round để chạy tiếp khi bị ngắt.

Phụ lục A. Cấu trúc code và lệnh chạy

Bảng 23. Các bước chạy

Bước	Lệnh	Đầu ra chính
Tiền xử lý + split	python scripts/01_preprocess.py	application_features.parquet, splits.parquet
Centralized tabular	python scripts/04a_train_centralized.py	centralized_baselines.json
Graph toàn cục	python scripts/03a_build_centralized_graph.py	centralized_graph.pt, graph_orphan_report.json
Centralized HeteroGNN	python scripts/04b_train_centralized_gnn.py	centralized_baselines.json (hetero_gnn)
Chia client	python scripts/02_partition_clients.py [--scenario]	partitions/<scenario>.parquet, partition_report.json
Local graph	python scripts/03_build_graphs.py [--scenario]	client_graphs/<scenario>/client_k.pt
Federated + PFL	python scripts/04_train_federated.py [--methods ...] [--scenario]	federated_results.json
Đánh giá	python scripts/05_evaluate.py [--scenario]	comparison.json, CSV

Module chính: src/preprocessing (làm sạch, aggregate, encoder), src/graph (schema, node/edge builder, orphan_check, heterograph_builder, graph_split), src/models (baselines, hetero_gnn), src/partition (Dirichlet theo nhãn, theo vùng, thống kê non-IID), src/federated (federated_encoder, client, server: FedAvg/FedProx/FedPer/Ditto, aggregation, fed_baselines, personalization), src/evaluation (metrics).

Môi trường: Python 3.12, PyTorch 2.3.1+cpu, PyTorch Geometric 2.6.1, LightGBM 4.7.0, scikit-learn 1.8.0; CPU 16 luồng, RAM 16 GB.