KHÓA LUẬN TỐT NGHIỆP

Personalized Federated Heterogeneous Graph Learning for Credit Risk Prediction

BÁO CÁO TỔNG HỢP: CƠ SỞ LÝ THUYẾT, CÁCH CHIA DỮ LIỆU, PIPELINE, KẾT QUẢ VÀ KẾT LUẬN

Bộ dữ liệu: Home Credit Default Risk (Kaggle)

Người thực hiện: Anh Thu
Ngày cập nhật: 29/10/2026
Mã nguồn: repo home_credit_fedheterognn

Tóm tắt

Đề tài dự đoán khả năng vỡ nợ của khách hàng vay tiêu dùng khi dữ liệu nằm ở nhiều tổ chức tín dụng không được chia sẻ dữ liệu khách hàng cho nhau. Dữ liệu quan hệ của Home Credit (7 bảng, khoảng 26.6 triệu bản ghi lịch sử) được biểu diễn thành heterogeneous graph với 6 loại node và 10 loại cạnh, mô hình HeteroGNN học trực tiếp từ chuỗi sự kiện tín dụng của từng khách hàng. Dữ liệu được chia cho 5 tổ chức mô phỏng theo địa bàn vùng sinh sống, quy mô tổ chức theo Dirichlet(α = 0.5). Các phương pháp được so sánh gồm Centralized (Logistic Regression, LightGBM, HeteroGNN), Local-only, FedAvg, bốn phương pháp Personalized FL (Fine-tune, FedProx, FedPer, Ditto) và một hướng Hybrid Personalized FL đề xuất, trên cùng tập Test 46,127 khách hàng, đánh giá theo từng tổ chức với khoảng tin cậy bootstrap và lặp lại 3 seed.

Kết quả chính: (1) HeteroGNN tập trung đạt ROC-AUC 0.7858, tốt hơn Logistic Regression (0.7832) nhưng kém LightGBM (0.7931). (2) FedAvg tốt hơn Local-only ở cả 5 tổ chức trong cả 3 seed (+0.0165 AUC trung bình, đến +0.03 ở tổ chức nhỏ) và gần bằng huấn luyện tập trung. (3) Trong kịch bản chia theo vùng, dữ liệu gần như không có concept shift nên Personalized FL đơn lẻ không vượt FedAvg; Ditto chỉ có lợi ở tổ chức nhỏ và đặc thù nhất. (4) Hybrid Ditto + Local LightGBM đạt 0.7905, hơn FedAvg +0.0070 ổn định qua 3 seed, vượt HeteroGNN tập trung và chỉ kém LightGBM tập trung 0.0023.

Mục lục

1. Giới thiệu
2. Cơ sở lý thuyết
3. Dữ liệu và tiền xử lý
4. Chia dữ liệu cho Federated Learning
5. Pipeline bài toán
6. Kết quả thực nghiệm
7. Thảo luận: trả lời các câu hỏi nghiên cứu
8. Hạn chế và hướng phát triển
9. Kết luận

Tài liệu tham khảo

1. Giới thiệu

1.1. Bối cảnh

Chấm điểm tín dụng là bài toán ước lượng xác suất một khách hàng không trả được nợ. Hai đặc điểm làm bài toán khó trong thực tế. Thứ nhất, dữ liệu tín dụng có cấu trúc quan hệ: mỗi khách hàng có nhiều hồ sơ vay trước, mỗi hồ sơ có nhiều kỳ trả góp hay bản ghi thẻ theo tháng. Cách làm phổ biến là tổng hợp (aggregate) các bảng này thành đặc trưng cố định, đánh mất một phần thông tin chi tiết. Thứ hai, dữ liệu nằm rải rác ở nhiều tổ chức (ngân hàng địa phương, công ty tài chính, chi nhánh) và không thể gom về một chỗ do quy định bảo vệ dữ liệu cá nhân (có thể tham chiếu Nghị định 13/2023/NĐ-CP và Luật Các tổ chức tín dụng 2024). Tổ chức nhỏ có ít dữ liệu và ít ca vỡ nợ nên khó tự xây mô hình tốt.

Đề tài kết hợp hai hướng: **heterogeneous graph learning** để học trực tiếp từ cấu trúc quan hệ, và **Federated Learning** (FL) để các tổ chức cùng huấn luyện mô hình mà chỉ trao đổi tham số. Vì các tổ chức phục vụ những nhóm khách hàng khác nhau, đề tài nghiên cứu thêm **Personalized FL**: mỗi tổ chức có mô hình được điều chỉnh cho dữ liệu của mình.

1.2. Câu hỏi nghiên cứu

- **Q1.** Biểu diễn dữ liệu tín dụng dạng heterogeneous graph có dự đoán tốt không so với mô hình bảng truyền thống?
- **Q2.** Federated Learning có tốt hơn việc mỗi tổ chức tự huấn luyện không, và kém bao nhiêu so với gom dữ liệu về một chỗ?
- **Q3.** Trong trường hợp dữ liệu giữa các client khác nhau nhiều (non-IID), Personalized FL có lợi thế gì so với FedAvg truyền thống? Và trong trường hợp nào FedAvg vẫn phù hợp hơn?

1.3. Đóng góp

- Pipeline đầy đủ từ dữ liệu quan hệ đến heterogeneous graph, có xử lý dữ liệu mồ côi (orphan records) và chống rò rỉ dữ liệu; cùng một split dùng cho cả nhánh tập trung và nhánh federated.
- Cách chia dữ liệu cho FL dựa trên thuộc tính có thật của dữ liệu (vùng sinh sống), không dùng nhãn, kèm phân tích đối chiếu với phân loại non-IID trong tài liệu.
- So sánh có kiểm soát giữa 3 baseline tập trung (Logistic Regression, LightGBM, HeteroGNN), 2 baseline FL (Local-only, FedAvg), 4 phương pháp Personalized FL (FedAvg + Fine-tune, FedProx, FedPer, Ditto) và hướng Hybrid Personalized FL đề xuất (FedAvg + Ditto, FedAvg + Local LightGBM, Ditto + Local LightGBM), đánh giá theo từng tổ chức với paired bootstrap; các mô hình chính (HeteroGNN tập trung, Local-only, FedAvg, Ditto, Hybrid) được lặp lại với 3 seed (42, 1, 2).
- Phân tích concept shift giữa các tổ chức để giải thích khi nào cá nhân hóa có ích.

2. Cơ sở lý thuyết

2.1. Bài toán và ký hiệu

Mỗi khách hàng i có đặc trưng x_i (hồ sơ hiện tại và lịch sử tín dụng) và nhãn y_i thuộc {0, 1}, $y_i = 1$ nếu vỡ nợ. Mô hình ước lượng $p_i = P(y_i = 1 \mid x_i)$ và được huấn luyện bằng binary cross-entropy:

$$\ell(p, y) = -\,[\, y \cdot \log p + (1 - y) \cdot \log(1 - p) \,]$$

Dữ liệu mất cân bằng (8.07% vỡ nợ) nên đánh giá chủ yếu bằng ROC-AUC và PR-AUC, không dùng accuracy. Trong FL có K client, client k giữ tập dữ liệu D_k gồm n_k khách hàng.

2.2. Logistic Regression

Mô hình tuyến tính $p = \sigma(w^T x + b)$, với σ là hàm sigmoid, huấn luyện với phạt L2 có hệ số 1/C. Ưu điểm là dễ giải thích và ổn định; nhược điểm là không tự học tương tác phi tuyến. Trong đề tài, đặc trưng số được clip theo quantile 1%/99%, điền median kèm cờ thiếu, chuẩn hóa; đặc trưng phân loại được one-hot.

2.3. LightGBM (Gradient Boosting Decision Tree)

Gradient boosting xây dựng mô hình cộng $F_M(x) = \Sigma_m\, \eta \cdot f_m(x)$, mỗi cây f_m được khớp với gradient âm của hàm mất mát tại F_{m-1}, η là learning rate. LightGBM (Ke et al., 2017) tăng tốc bằng histogram, phát triển cây theo lá (leaf-wise) và lấy mẫu đặc trưng. Đây là mô hình mạnh nhất cho dữ liệu bảng và là baseline tham chiếu phổ biến của Home Credit. Số cây chọn bằng early stopping theo AUC Validation.

2.4. Graph Neural Network trên heterogeneous graph

Heterogeneous graph G = (V, E) có nhiều loại node và loại cạnh; mỗi loại node t có đặc trưng riêng với số chiều d_t. GNN học biểu diễn node bằng **message passing**: ở mỗi tầng, mỗi node tổng hợp thông tin từ các node lân cận rồi cập nhật biểu diễn của mình. Sau L tầng, node nhận được thông tin từ vùng lân cận cách nó tối đa L bước. Đề tài có 6 loại node và 10 loại cạnh.

GraphSAGE (Hamilton et al., 2017) với hàm gộp trung bình, N(v) là lân cận của v, W_1, W_2 học được:

$$h_v^{(l+1)} = W_1\, h_v^{(l)} + W_2 \cdot \text{mean}_{u \in N(v)}\, h_u^{(l)}$$

Với heterogeneous graph, **HeteroConv** dùng một SAGEConv riêng cho mỗi loại cạnh r = (s → t) rồi cộng kết quả của các loại cạnh cùng đi vào loại node t (ví dụ prev, bureau → customer):

$$m_v = \Sigma_{r:\,(s \to t)}\, \text{SAGE}_r(h_v, \{h_u : u \in N_r(v)\}),\; h_v \leftarrow h_v + \text{Dropout}(\text{ReLU}(\text{LayerNorm}(m_v)))$$

Kiến trúc dùng trong đề tài: mỗi loại node có encoder tuyến tính riêng (Linear → LayerNorm → ReLU) đưa đặc trưng về cùng 64 chiều; tiếp theo 2 tầng HeteroConv(SAGEConv, mean) có residual và LayerNorm; tầng cuối chỉ tính các cạnh đi vào customer; cuối cùng là MLP phân loại trên embedding customer. Với 2 tầng, tầng 1 đưa thông tin từ kỳ trả góp, POS, thẻ lên hồ sơ vay trước và từ bureau, prev lên customer; tầng 2 đưa hồ sơ vay trước (đã chứa thông tin sự kiện) lên customer. Huấn luyện bằng AdamW (lr 0.001), batch 1,024 khách hàng, mỗi batch lấy trọn cây con của khách hàng. Dropout 0.2, weight decay 0.00001; HeteroGNN tập trung train tối đa 30 epoch, patience 4.

2.5. Federated Learning và FedAvg

Đề tài thuộc **horizontal FL**: các client có cùng loại đặc trưng nhưng khác tập khách hàng. Mục tiêu là tìm mô hình chung w tối ưu hàm mất mát có trọng số của mọi client mà không gom dữ liệu:

$$\min_w F(w) = \Sigma_{k=1..K}\, (n_k / n) \cdot F_k(w),\; F_k(w) = (1/n_k)\, \Sigma_{i \in D_k}\, \ell(f_w(x_i), y_i)$$

FedAvg (McMahan et al., 2017): ở mỗi round t, server gửi w^t cho các client; mỗi client train E epoch cục bộ trên dữ liệu của mình được w_k^{t+1}; server gộp theo số mẫu:

$$w^{t+1} = \Sigma_k (n_k / n) \cdot w_k^{t+1}$$

Chỉ tham số mô hình (và các thống kê tổng hợp để dựng encoder) được trao đổi; dữ liệu và nhãn ở lại client. Hai mốc so sánh tự nhiên là **Local-only** (mỗi client tự train, cận dưới) và **Centralized** (gom dữ liệu, cận trên).

2.6. Dữ liệu non-IID

FedAvg hoạt động tốt nhất khi dữ liệu các client cùng phân phối (IID). Theo Kairouz et al. (2021) và Li et al. (2022), dữ liệu non-IID gồm các dạng chính:

- **Quantity skew:** client có lượng dữ liệu rất khác nhau.
- **Feature skew (covariate shift):** $P_k(x)$ khác nhau, ví dụ thu nhập, điểm tín dụng khác giữa vùng.
- **Label skew:** $P_k(y)$ khác nhau, ví dụ tỷ lệ vỡ nợ khác giữa tổ chức.
- **Concept shift:** $P_k(y \mid x)$ khác nhau, tức cùng một hồ sơ nhưng rủi ro khác nhau ở mỗi tổ chức. Đây là dạng khiến một mô hình chung không thể tối ưu cho mọi client.

Để mô phỏng, tài liệu thường dùng **phân phối Dirichlet**: $q \sim \mathrm{Dir}(\alpha \cdot 1_K)$ cho một vector tỷ lệ có tổng bằng 1; α càng nhỏ thì các tỷ lệ càng chênh lệch. Li et al. (2022) dùng q để chia quy mô (quantity skew); Hsu et al. (2019) dùng Dirichlet trên từng nhãn (label skew).

2.7. Personalized Federated Learning

Khi dữ liệu non-IID, một mô hình chung có thể không tốt cho từng client. Personalized FL cho mỗi client k một mô hình riêng v_k, vẫn tận dụng tri thức chung. Bốn phương pháp được cài đặt:

FedAvg + Fine-tune. Sau khi FedAvg hội tụ, mỗi client train thêm mô hình chung trên dữ liệu của mình (lr 0.0005, tối đa 10 epoch), chọn epoch tốt nhất theo AUC Val; epoch 0 (giữ nguyên FedAvg) cũng là ứng viên.

FedProx (Li et al., 2020). Không cá nhân hóa mà ổn định huấn luyện khi non-IID bằng cách thêm số hạng gần (proximal) giữ mô hình cục bộ không đi quá xa mô hình chung:

$$\min_w F_k(w) + (\mu / 2) \cdot \|w - w^t\|^2, \ \mu = 0.01$$

FedPer (Arivazhagan et al., 2019). Chia mô hình thành phần chung (encoder và các tầng GNN, gộp bằng FedAvg) và phần riêng (head phân loại, ở lại client). Mỗi client dùng biểu diễn chung nhưng ranh giới quyết định riêng.

Ditto (Li et al., 2021). Song song với mô hình chung w (train như FedAvg), mỗi client giữ một mô hình riêng v_k được kéo về mô hình chung:

$$\min_{v_k} F_k(v_k) + (\lambda / 2) \cdot \|v_k - w^*\|^2, \ \lambda = 0.1$$

λ lớn thì v_k gần mô hình chung; λ nhỏ thì gần Local-only. Một λ chung được dùng cho mọi client.

2.8. Hybrid Personalized FL (hướng đề xuất)

Ý tưởng gần với APFL (Deng et al., 2020): dự đoán của mỗi client là tổ hợp của mô hình chung và mô hình cục bộ, với hệ số trộn riêng cho từng client. Đề tài trộn ở mức dự đoán, trên thang logit:

$$\mathrm{logit}(p_k^{\mathrm{hybrid}}) = w_k \cdot \mathrm{logit}(p^A) + (1 - w_k) \cdot \mathrm{logit}(p^B), \ w_k \in \{0; 0.05; \ldots; 1\}$$

A là thành phần federated (FedAvg hoặc Ditto), B là thành phần cục bộ (Ditto, hoặc LightGBM train chỉ trên Train của client với 601 đặc trưng bảng). w_k chọn theo AUC trên Validation của client k. Vì $w_k = 0$ và $w_k = 1$ là ứng viên, trên Validation hybrid không kém thành phần tốt hơn. Khác với Ditto dùng một λ chung, mỗi client tự chọn mức cá nhân hóa. Không có dữ liệu hay dự đoán nào rời khỏi client.

2.9. Phương pháp đánh giá

- **ROC-AUC:** xác suất mô hình xếp một ca vỡ nợ ngẫu nhiên cao hơn một ca không vỡ nợ ngẫu nhiên; không phụ thuộc threshold và tỷ lệ nền. Đây là chỉ số chính.
- **PR-AUC:** diện tích dưới đường precision-recall, nhạy với lớp thiểu số.
- **KS:** max(TPR − FPR), chỉ số truyền thống trong chấm điểm tín dụng.
- **F1, precision, recall** tại threshold chọn trên Validation (max F1).
- **Đánh giá theo client:** AUC trên Test của từng client, AUC trung bình có trọng số theo số khách hàng Test và AUC của client kém nhất. Không dùng AUC gộp vì khi các client có tỷ lệ nền khác nhau, AUC gộp có thể tăng giả tạo.
- **Paired bootstrap** (1,000 lần): lấy mẫu lại Test của client có hoàn lại, tính chênh lệch AUC của hai mô hình trên cùng mẫu; khoảng tin cậy 95% không chứa 0 nghĩa là khác biệt có ý nghĩa thống kê.
- **Nhiều seed:** lặp lại huấn luyện với seed 42, 1, 2 để đo dao động do khởi tạo và thứ tự batch; báo cáo mean ± std và số seed có chênh lệch dương.

3. Dữ liệu và tiền xử lý

3.1. Các bảng dữ liệu

Bảng 1. Các bảng của Home Credit Default Risk

Bảng	Khóa	Vai trò
application_train	SK_ID_CURR	Hồ sơ vay hiện tại, có TARGET (307,511 dòng, 8.07% vỡ nợ)
application_test	SK_ID_CURR	Không có TARGET (48,744 dòng), chỉ dùng nộp Kaggle
bureau / bureau_balance	SK_ID_BUREAU	Lịch sử tín dụng ở tổ chức khác, trạng thái theo tháng
previous_application	SK_ID_PREV	Hồ sơ vay trước đây tại Home Credit
installments_payments	SK_ID_PREV	Từng kỳ trả góp
POS_CASH_balance	SK_ID_PREV	Bản ghi POS / tiền mặt theo tháng
credit_card_balance	SK_ID_PREV	Bản ghi thẻ tín dụng theo tháng

3.2. Quyết định về tập đánh giá

application_test.csv không có cột TARGET nên không thể tính metric. Mọi tập có nhãn vì vậy đều tách từ application_train: một split duy nhất Train/Validation/Test = 70/15/15, stratified theo TARGET, seed 42, dùng chung cho cả hai nhánh. Khi chia client, mỗi khách hàng giữ nguyên nhãn split của mình, nên hợp Test của 5 client đúng bằng Test chung và hai nhánh được so sánh trên cùng khách hàng.

Bảng 2. Split chung

Tập	Số khách hàng	Tỷ lệ vỡ nợ
Train	215,257	8.07%
Validation	46,127	8.07%
Test	46,127	8.07%

3.3. Làm sạch và đặc trưng bảng

- DAYS_EMPLOYED = 365243 (giá trị giữ chỗ) thành NaN kèm cờ; CODE_GENDER, ORGANIZATION_TYPE = XNA thành NaN; các cột DAYS_* = 365243 trong previous_application thành NaN.
- Đặc trưng tỷ lệ tài chính: CREDIT/INCOME, ANNUITY/INCOME, PAYMENT_RATE, GOODS/CREDIT, các thống kê của EXT_SOURCE (mean, std, min, tích).
- Aggregate theo SK_ID_CURR từ 6 bảng phụ, kèm thống kê riêng cho khoản Active/Closed và Approved/Refused. Tổng cộng 601 đặc trưng cho mô hình bảng.

3.4. Dữ liệu mồ côi (orphan records)

Bảng 3. Orphan records và cách xử lý

Trường hợp	Mức độ	Cách xử lý
Event trỏ tới SK_ID_PREV không có trong previous_application	27.0% dòng thẻ, 8.8% kỳ trả góp, 3.4% POS	Tạo 39,894 node prev giữ chỗ (IS_PLACEHOLDER = 1)
Hồ sơ vay trước không có lịch sử trả	565,528 hồ sơ, chủ yếu bị từ chối hoặc hủy	Không phải lỗi; giữ node, thêm đặc trưng N_* và cờ HAS_*
Khách hàng không có lịch sử	Không bureau 44,020; không prev 14,697; không cả hai 2,200	Giữ node; mô hình dùng đặc trưng của chính node qua residual
bureau_balance không trỏ tới bureau nào	3,120,184 dòng	Bỏ, vì không nối được về khách hàng

3.5. Kiểm soát rò rỉ dữ liệu

- Mọi encoder (clip quantile, median, chuẩn hóa, one-hot, danh mục) chỉ fit trên Train.

- Validation chỉ dùng để chọn siêu tham số, early stopping, checkpoint và threshold; Test chỉ đánh giá một lần.
- Mỗi bản ghi lịch sử thuộc đúng một khách hàng, nên graph là tập các cây tách rời, mỗi khách hàng là gốc một cây. Không có thông tin đi từ khách hàng Val/Test sang Train qua graph, và chia graph theo client không làm mất cạnh nào. Mặt trái là GNN chỉ học cách tổng hợp lịch sử của từng khách hàng, không khai thác quan hệ giữa các khách hàng.
- AUC Validation và Test của các mô hình tập trung chênh nhau dưới 0.003: không có dấu hiệu overfit hay leakage.

4. Chia dữ liệu cho Federated Learning

4.1. Lý do chia theo vùng

Home Credit là một tổ chức duy nhất, nên phải tự chia dữ liệu thành nhiều tổ chức mô phỏng. Các tổ chức tín dụng (quỹ tín dụng nhân dân, ngân hàng địa phương, công ty tài chính khu vực) thường hoạt động theo địa bàn, nên chia theo vùng hợp lý hơn chia ngẫu nhiên hay theo nhãn. Dữ liệu không có cột mã vùng, nhưng REGION_POPULATION_RELATIVE (mật độ dân số chuẩn hóa của vùng khách hàng sinh sống) chỉ có 81 giá trị rời rạc và mỗi giá trị ứng đúng một REGION_RATING_CLIENT (100% trường hợp). Mỗi giá trị vì vậy được coi là một vùng đã ẩn danh; đây là suy luận từ dữ liệu và được ghi nhận là giả định.

Bảng 4. Quy tắc sở hữu client

Quy tắc	Nội dung
R1	Mỗi khách hàng thuộc đúng một client
R2	Khách hàng thuộc tổ chức phụ trách vùng nơi họ sinh sống
R3	Mỗi vùng do đúng một tổ chức phụ trách; Dirichlet chỉ quyết định quy mô tổ chức
R4	Toàn bộ lịch sử của khách hàng (bureau, previous, installments, POS, credit card) đi theo client sở hữu
R5	Nhãn, split và dữ liệu thô ở lại client; chỉ trao đổi trọng số mô hình và thống kê tổng hợp

4.2. So sánh các cách chia và lựa chọn

Bảng 5. So sánh các cách chia client

Cách chia	Quy mô client	Tỷ lệ vỡ nợ	Đánh giá
Dirichlet theo nhãn (α = 0.5)	2.5% – 78%	3.1% – 72%	Phi thực tế (dùng TARGET khi chia); giữ làm stress test
P1: theo hạng vùng	10% – 25%	4.8% – 11.1%	Dễ giải thích nhưng các client đều lớn
P2: thị phần mỗi vùng ~ Dir(0.5)	14% – 26%	7.8% – 8.4%	Loại: gần như IID
P3: địa bàn độc quyền, quy mô ~ Dir(0.5)	3.2% – 47.4%	7.6% – 9.3%	**Kịch bản chính**

4.3. Quy trình chia của kịch bản chính region_territory_a0.5

- **Bước 1, quy mô:** lấy mẫu q ~ Dirichlet(α = 0.5) cho 5 tổ chức. Lần được chấp nhận: q = [10.8%, 9.4%, 4.5%, 27.4%, 47.9%].
- **Bước 2, địa bàn:** xếp 81 vùng theo thứ tự ngẫu nhiên, lần lượt giao từng vùng cho tổ chức đang thiếu khách hàng nhiều nhất so với quy mô mục tiêu. Mỗi vùng được giao nguyên vẹn, nên quy mô thực tế xấp xỉ q.
- **Bước 3, khách hàng:** khách hàng thuộc tổ chức phụ trách vùng của họ, kéo theo toàn bộ lịch sử tín dụng.
- **Bước 4, ràng buộc:** loại lần lấy mẫu nếu có tổ chức dưới 3% khách hàng hoặc dưới 30 mẫu mỗi lớp ở Train/Val/Test (kịch bản chính được chấp nhận ở lần thứ 2).

Bảng 6. Đặc điểm các client trong kịch bản region_territory_a0.5

Client	Khách hàng	Tỷ trọng	Vỡ nợ	Số vùng	Vùng hạng 1	Vùng hạng 3	W(EXT_SOURCE_2)	Train / Val / Test
C0	34,805	11.3%	7.6%	10	1.8%	6.4%	0.110	24,443 / 5,101 / 5,261
C1	25,860	8.4%	8.5%	5	0.0%	13.3%	0.047	18,050 / 4,025 / 3,785
C2	9,866	3.2%	9.2%	3	0.0%	0.0%	0.195	6,875 / 1,539 / 1,452
C3	91,159	29.6%	8.2%	23	9.2%	21.4%	0.016	63,733 / 13,700 / 13,726
C4	145,821	47.4%	8.0%	40	15.9%	15.9%	0.011	102,156 / 21,762 / 21,903

W(EXT_SOURCE_2): khoảng cách Wasserstein giữa phân phối EXT_SOURCE_2 của client và toàn cục, chuẩn hóa theo độ lệch chuẩn; lớn nghĩa là lệch đặc trưng mạnh. C2 là client nhỏ nhất và đặc thù nhất.

4.4. Đối chiếu với phân loại non-IID

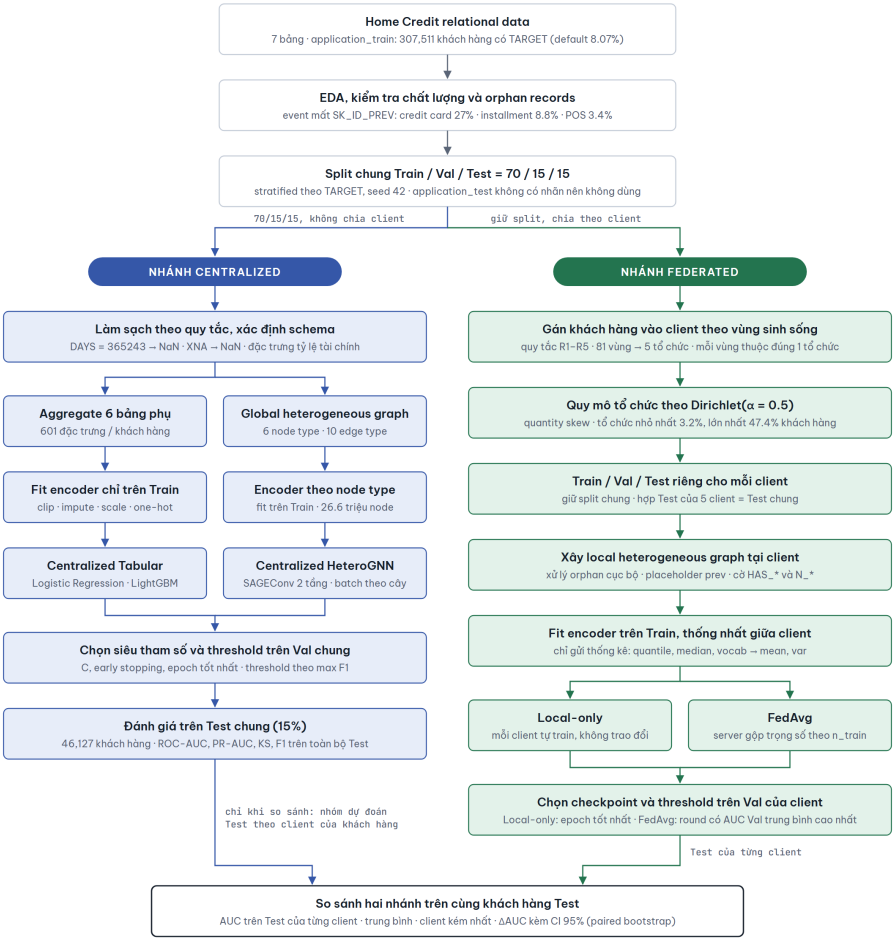
Bảng 7. Kịch bản chính theo các dạng non-IID

Dạng non-IID	Trong kịch bản chính
Quantity skew	Có, theo Dirichlet(0.5): 3.2% – 47.4%
Feature skew	Có, tự nhiên theo vùng: thu nhập, EXT_SOURCE khác nhau (W đến 0.195)
Label skew	Rất nhẹ, không cố tạo: 7.6% – 9.3%
Concept shift	Gần như không có (kiểm định ở mục 6.5)

4.5. Các kịch bản phụ

- **income_mix_a0.5** (cơ cấu danh mục): mọi tổ chức phục vụ mọi nhóm thu nhập (NAME_INCOME_TYPE gộp thành Working, Commercial, Pensioner, State servant) nhưng có thế mạnh riêng. Với mỗi nhóm s, tỷ lệ giao cho các tổ chức là $p_s = (1 - 0.1) \cdot \mathrm{Dir}(0.5) + 0.1/K$. Quy mô 5.2% – 45.3%, vỡ nợ 7.7% – 9.1%. Hiện mới chạy bước chia và phân tích concept shift.
- **label_dirichlet_a0.5** (stress test): Dirichlet trên TARGET (Hsu et al., 2019), tạo một client có 72% khách hàng vỡ nợ và một client chiếm 78% dữ liệu. Phi thực tế vì tổ chức không thể phân khách hàng theo kết quả vỡ nợ; chỉ dùng để thử FL khi lệch nhãn cực đoan.

5. Pipeline bài toán



Hình 1. Pipeline của đề tài. Xanh lam: nhánh Centralized; xanh lục: nhánh Federated. Các phương pháp Personalized FL và Hybrid nằm ở khối huấn luyện và chọn checkpoint của nhánh Federated.

5.1. Nhánh Centralized

- Tiền xử lý và tạo 601 đặc trưng bảng; fit encoder trên Train; huấn luyện Logistic Regression (C chọn trong {0.001, 0.01, 0.1}, tốt nhất C = 0.01) và LightGBM (early stopping 200 vòng, tốt nhất 1,488 cây).
- Dựng heterogeneous graph toàn cục, kiểm tra cạnh hợp lệ, mỗi node con có đúng một node cha, cạnh ngược khớp cạnh xuôi; encoder theo từng loại node fit trên Train; huấn luyện HeteroGNN (epoch tốt nhất 6, 316 giây).

Bảng 8. Node type của graph toàn cục

Node type	Định danh	Số node	Số đặc trưng	Ý nghĩa
customer	SK_ID_CURR	307,511	300	Hồ sơ vay hiện tại (chỉ đặc trưng application)
bureau	SK_ID_BUREAU	1,465,325	61	Tín dụng ở tổ chức khác, gộp bureau_balance
prev	SK_ID_PREV	1,453,595	168	Hồ sơ vay trước (gồm node giữ chỗ)
installment	theo sự kiện	11,591,592	17	Kỳ trả góp
pos	theo tháng	8,543,375	11	Bản ghi POS / tiền mặt
cc	theo tháng	3,227,965	36	Bản ghi thẻ tín dụng

Cạnh: customer → bureau, customer → prev, prev → installment / pos / cc, cùng 5 cạnh ngược; tổng 10 edge type.

5.2. Nhánh Federated

- Chia khách hàng cho 5 client theo mục 4; mỗi client tự dựng local graph, tự xử lý orphan; tổng số node giữ chỗ của 5 client bằng đúng số của graph toàn cục.
- **Encoder thống nhất** qua 2 vòng trao đổi thống kê trên Train của client: vòng 1 gửi quantile, median, cờ có-missing, tần suất category; vòng 2 gửi n, tổng và tổng bình phương để server tính mean/std. Mọi client có cùng số chiều đặc trưng (customer 313, bureau 64, prev 173, installment 17, pos 12, cc 37), điều kiện để gộp trọng số.
- Huấn luyện Local-only, FedAvg và các phương pháp Personalized FL; cùng kiến trúc và cùng khởi tạo với HeteroGNN tập trung.
- Checkpoint chọn theo AUC Validation trung bình có trọng số (theo số mẫu Val) của mô hình mà mỗi client thực sự dùng; threshold của từng client chọn trên Val của client đó.
- Hybrid: trộn dự đoán theo mục 2.8, trọng số chọn trên Val của từng client.

Bảng 9. Cấu hình huấn luyện các phương pháp Federated

Phương pháp	Cấu hình	Checkpoint tốt nhất (seed 42)	Thời gian CPU
Local-only	tối đa 30 epoch, patience 4	epoch 8, 8, 13, 6, 5	662 giây
FedAvg	tối đa 40 round, 1 epoch cục bộ, patience 6	round 15	880 giây
FedAvg + Fine-tune	lr 0.0005, tối đa 10 epoch, patience 2	epoch 1, 3, 0, 0, 0	158 giây
FedProx	μ = 0.01	round 30	2,560 giây
FedPer	head phân loại riêng ở client	round 17	1,515 giây
Ditto	λ = 0.1	round 15	5,158 giây
Hybrid	lưới w bước 0.05; Local LightGBM như Centralized	w chọn trên Val	khoảng 8 phút / seed

Bảng 10. Các bước chạy

Bước	Script	Nội dung
1	01_preprocess.py	Làm sạch, 601 đặc trưng bảng, split chung 70/15/15
2	04a_train_centralized.py	Logistic Regression, LightGBM
3	03a_build_centralized_graph.py	Graph toàn cục, kiểm tra orphan
4	04b_train_centralized_gnn.py	HeteroGNN tập trung
5	02_partition_clients.py	Chia client theo kịch bản
6	03_build_graphs.py	Local graph và encoder thống nhất
7	04_train_federated.py	Local-only, FedAvg, Personalized FL
8	05_evaluate.py	So sánh theo client, paired bootstrap
9	06_concept_shift.py	Phân tích concept shift
10	07_aggregate_seeds.py	Tổng hợp kết quả nhiều seed
11	08_hybrid_personalization.py	Hybrid Personalized FL

6. Kết quả thực nghiệm

6.1. Nhánh Centralized trên Test chung

Bảng 11. Kết quả Centralized trên Test chung (46,127 khách hàng, seed 42)

Mô hình	ROC-AUC	PR-AUC	KS	Brier	F1	Precision	Recall
Logistic Regression	0.7832	0.2775	0.4317	0.0661	0.3376	0.2724	0.4436
LightGBM	**0.7931**	**0.2951**	**0.4448**	**0.0653**	**0.3495**	0.2965	0.4256
HeteroGNN	0.7858	0.2819	0.4365	0.0659	0.3370	0.2742	0.4372

AUC Validation: LR 0.7802, LightGBM 0.7919, HeteroGNN 0.7834. Đặc trưng quan trọng nhất của LightGBM: EXT_SOURCE_MEAN, EXT_SOURCE_MIN, ORGANIZATION_TYPE, EXT_SOURCE_3, PAYMENT_RATE.

HeteroGNN tốt hơn Logistic Regression dù node customer chỉ dùng đặc trưng application (300 cột), tức graph đã học được thông tin hữu ích từ lịch sử tín dụng chi tiết. LightGBM vẫn mạnh nhất nhờ 601 đặc trưng tổng hợp được thiết kế thủ công.

6.2. Kịch bản chính: kết quả theo client (seed 42)

Bảng 12. ROC-AUC trên Test của từng client (seed 42)

Nhóm	Mô hình	C0	C1	C2	C3	C4	TB	Kém nhất
Cận trên	Centralized LR	0.7827	0.7719	0.7889	0.7845	0.7835	0.7829	0.7719
Cận trên	Centralized LightGBM	0.7898	0.7834	0.7879	0.7946	0.7945	0.7928	0.7834
Cận trên	Centralized HeteroGNN	0.7830	0.7752	0.7869	0.7875	0.7869	0.7856	0.7752
FL baseline	Local-only	0.7491	0.7463	0.7701	0.7718	0.7733	0.7678	0.7463
FL baseline	FedAvg	0.7775	0.7731	0.7789	0.7881	0.7838	0.7833	0.7731
PFL	FedAvg + Fine-tune	0.7731	0.7752	0.7789	0.7881	0.7838	0.7830	0.7731
PFL	FedProx	0.7739	0.7671	0.7839	0.7822	0.7802	0.7791	0.7671
PFL	FedPer	0.7754	0.7732	0.7830	0.7878	0.7823	0.7824	0.7732
PFL	Ditto	0.7794	0.7747	0.7871	0.7868	0.7807	0.7821	0.7747

Các mô hình Centralized được train một lần trên toàn bộ Train; cột theo client là AUC của cùng mô hình tính trên khách hàng Test của client đó. "TB" có trọng số theo số khách hàng Test.

Bảng 13. Chênh lệch ROC-AUC kèm khoảng tin cậy 95% (paired bootstrap, seed 42)

So sánh	C0	C1	C2	C3	C4
FedAvg − Local-only	**+0.028*** [+0.012, +0.045]	**+0.027*** [+0.012, +0.043]	+0.009 [−0.020, +0.037]	**+0.016*** [+0.010, +0.023]	**+0.011*** [+0.006, +0.015]
FedAvg − Centralized HeteroGNN	−0.005 [−0.015, +0.003]	−0.002 [−0.010, +0.007]	−0.008 [−0.021, +0.004]	+0.001 [−0.004, +0.005]	−0.003 [−0.007, +0.001]
FedProx − FedAvg	−0.004 [−0.012, +0.005]	−0.006 [−0.015, +0.003]	+0.005 [−0.009, +0.019]	**−0.006*** [−0.011, −0.001]	−0.004 [−0.008, +0.001]
FedPer − FedAvg	−0.002 [−0.008, +0.004]	+0.000 [−0.006, +0.005]	+0.004 [−0.005, +0.013]	−0.000 [−0.004, +0.003]	−0.001 [−0.004, +0.001]
Ditto − FedAvg	+0.002 [−0.004, +0.008]	+0.002 [−0.004, +0.007]	+0.008 [−0.002, +0.019]	−0.001 [−0.005, +0.003]	**−0.003*** [−0.006, −0.000]

Dấu * và in đậm: khoảng tin cậy không chứa 0.

6.3. Độ ổn định qua 3 seed

Bảng 14. ROC-AUC trên Test theo client, mean ± std qua 3 seed (42, 1, 2)

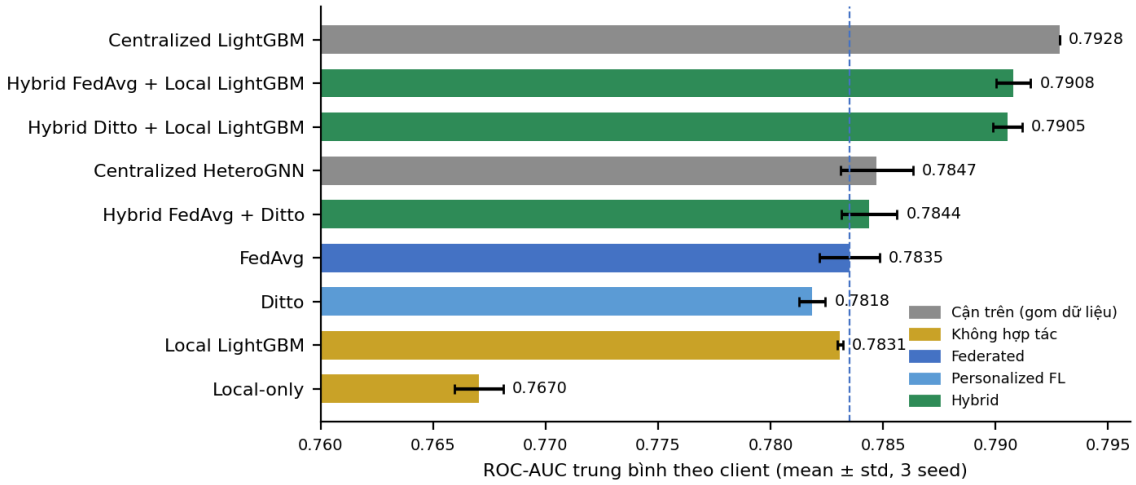
Mô hình	C0	C1	C2	C3	C4	TB client	Kém nhất
Centralized HeteroGNN	0.7810 ± 0.0018	0.7737 ± 0.0014	0.7864 ± 0.0005	0.7872 ± 0.0009	0.7858 ± 0.0023	0.7847 ± 0.0016	0.7737 ± 0.0014
Local-only	0.7490 ± 0.0018	0.7422 ± 0.0036	0.7662 ± 0.0035	0.7702 ± 0.0021	0.7737 ± 0.0014	0.7670 ± 0.0011	0.7422 ± 0.0036
FedAvg	0.7793 ± 0.0020	0.7738 ± 0.0035	0.7774 ± 0.0018	0.7868 ± 0.0013	0.7845 ± 0.0016	0.7835 ± 0.0013	0.7731 ± 0.0023
Ditto	0.7803 ± 0.0018	0.7728 ± 0.0033	0.7837 ± 0.0040	0.7861 ± 0.0019	0.7810 ± 0.0003	0.7818 ± 0.0006	0.7728 ± 0.0033

Bảng 15. Chênh lệch ROC-AUC trung bình qua 3 seed (số seed có chênh lệch dương)

So sánh	C0	C1	C2	C3	C4	TB client
FedAvg − Local-only	+0.0303 (3/3)	+0.0317 (3/3)	+0.0112 (3/3)	+0.0166 (3/3)	+0.0108 (3/3)	+0.0165 (3/3)
FedAvg − Centralized HeteroGNN	-0.0016 (1/3)	+0.0002 (1/3)	-0.0090 (0/3)	-0.0004 (2/3)	-0.0013 (1/3)	-0.0012 (1/3)
Ditto − FedAvg	+0.0010 (2/3)	-0.0010 (1/3)	+0.0063 (3/3)	-0.0007 (1/3)	-0.0035 (0/3)	-0.0017 (0/3)
Ditto − Centralized HeteroGNN	-0.0007 (1/3)	-0.0009 (1/3)	-0.0027 (1/3)	-0.0011 (1/3)	-0.0049 (0/3)	-0.0029 (0/3)

- **FedAvg tốt hơn Local-only ở 15/15 cặp client × seed.** Tổ chức nhỏ được lợi nhiều nhất: C0, C1 khoảng +0.03, C4 lớn nhất chỉ +0.011.
- **FedAvg tương đương Centralized HeteroGNN**: chênh lệch trung bình −0.0012, dấu đổi theo seed. Riêng C2 thấp hơn ở cả 3 seed (−0.0090).
- **Ditto là một đánh đổi:** tăng ổn định ở C2 (+0.0063, 3/3 seed) nhưng giảm ở C4 (−0.0035, 0/3 seed); trên tổng thể thấp hơn FedAvg ở cả 3 seed. Kết quả seed 42 hơi lạc quan về Ditto.
- Độ lệch chuẩn qua seed đến 0.004 AUC, lớn hơn phần lớn chênh lệch giữa các phương pháp PFL quan sát ở một seed; các so sánh FedPer, FedProx, Fine-tune với FedAvg (1 seed, chênh khoảng 0.002) chưa đủ để kết luận.

6.4. Hybrid Personalized FL



Hình 2. ROC-AUC trung bình theo client (có trọng số), mean ± std qua 3 seed; đường nét đứt là FedAvg.

Bảng 16. ROC-AUC của các phương pháp Hybrid, mean ± std qua 3 seed

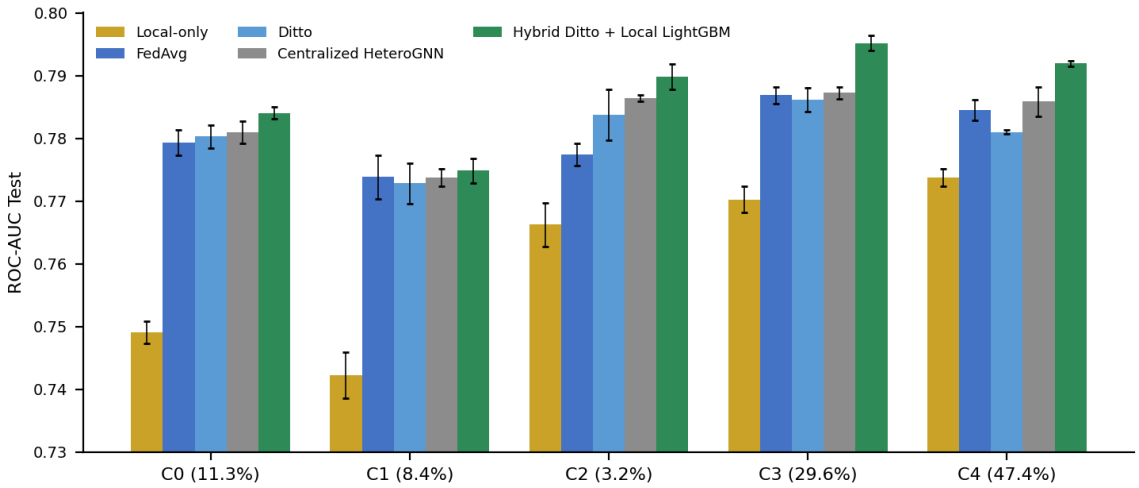
Mô hình	C0	C1	C2	C3	C4	TB client	Kém nhất
FedAvg	0.7793 ± 0.0020	0.7738 ± 0.0035	0.7774 ± 0.0018	0.7868 ± 0.0013	0.7845 ± 0.0016	0.7835 ± 0.0013	0.7731 ± 0.0023
Ditto	0.7803 ± 0.0018	0.7728 ± 0.0033	0.7837 ± 0.0040	0.7861 ± 0.0019	0.7810 ± 0.0003	0.7818 ± 0.0006	0.7728 ± 0.0033
Local LightGBM	0.7677 ± 0.0011	0.7570 ± 0.0033	0.7753 ± 0.0015	0.7889 ± 0.0003	0.7882 ± 0.0003	0.7831 ± 0.0001	0.7570 ± 0.0033
Hybrid FedAvg + Ditto	0.7814 ± 0.0013	0.7745 ± 0.0042	0.7832 ± 0.0025	0.7881 ± 0.0015	0.7846 ± 0.0012	0.7844 ± 0.0012	0.7745 ± 0.0042
Hybrid FedAvg + Local LightGBM	0.7834 ± 0.0018	0.7755 ± 0.0019	0.7855 ± 0.0018	0.7951 ± 0.0007	0.7929 ± 0.0009	0.7908 ± 0.0008	0.7755 ± 0.0019
Hybrid Ditto + Local LightGBM	0.7840 ± 0.0010	0.7748 ± 0.0020	0.7898 ± 0.0020	0.7952 ± 0.0012	0.7919 ± 0.0004	0.7905 ± 0.0006	0.7748 ± 0.0020

Centralized LightGBM (1 seed): TB client 0.7928, kém nhất 0.7834.

Bảng 17. Chênh lệch ROC-AUC của Hybrid, trung bình qua 3 seed (số seed có chênh lệch dương)

So sánh	C0	C1	C2	C3	C4	TB client
H: Ditto + Local LightGBM − FedAvg	+0.0047 (3/3)	+0.0010 (2/3)	+0.0124 (3/3)	+0.0083 (3/3)	+0.0074 (3/3)	+0.0070 (3/3)
H: Ditto + Local LightGBM − Ditto	+0.0037 (3/3)	+0.0020 (3/3)	+0.0060 (3/3)	+0.0090 (3/3)	+0.0110 (3/3)	+0.0087 (3/3)
H: Ditto + Local LightGBM − Centralized HeteroGNN	+0.0031 (3/3)	+0.0011 (2/3)	+0.0033 (3/3)	+0.0080 (3/3)	+0.0061 (3/3)	+0.0058 (3/3)
H: Ditto + Local LightGBM − Centralized LightGBM	-0.0057 (0/3)	-0.0086 (0/3)	+0.0019 (2/3)	+0.0006 (2/3)	-0.0025 (0/3)	-0.0023 (0/3)
H: FedAvg + Local LightGBM − FedAvg	+0.0041 (3/3)	+0.0017 (2/3)	+0.0081 (3/3)	+0.0082 (3/3)	+0.0084 (3/3)	+0.0073 (3/3)
H: FedAvg + Ditto − FedAvg	+0.0020 (3/3)	+0.0006 (2/3)	+0.0058 (3/3)	+0.0012 (3/3)	+0.0001 (2/3)	+0.0009 (3/3)
H: FedAvg + Ditto − Ditto	+0.0011 (2/3)	+0.0017 (3/3)	-0.0006 (1/3)	+0.0020 (3/3)	+0.0036 (3/3)	+0.0025 (3/3)

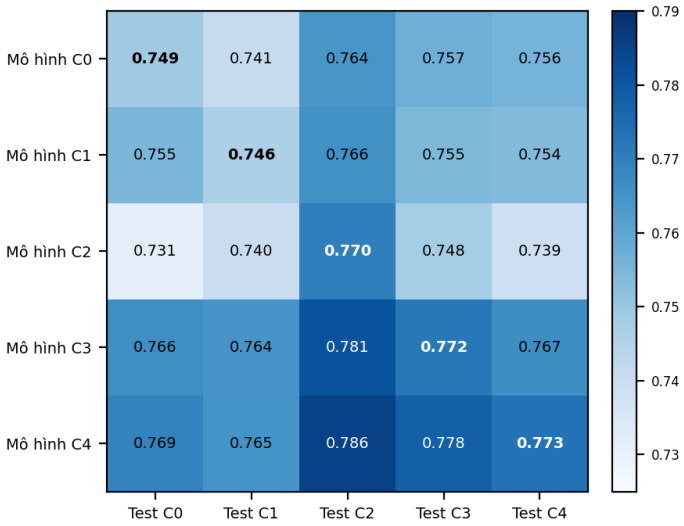
- **Hybrid Ditto + Local LightGBM** hơn FedAvg +0.0070 AUC (3/3 seed), hơn Ditto ở cả 5 client trong cả 3 seed; ở seed 42 chênh lệch so với FedAvg có ý nghĩa thống kê ở C2, C3, C4. Client C2 đạt 0.7898, cao hơn cả hai mô hình tập trung.
- Hybrid vượt Centralized HeteroGNN (+0.0058, 3/3 seed) và chỉ kém Centralized LightGBM 0.0023; ở seed 42 chênh lệch với Centralized LightGBM không có ý nghĩa thống kê ở client nào.
- Trọng số w (phần federated) ổn định qua seed và theo quy mô client: C4 luôn chọn w = 0.40 (dựa nhiều vào mô hình cục bộ); C2 chọn 0.75, 0.70, 0.75 (dựa nhiều vào tri thức chung).
- Local LightGBM đơn lẻ đạt 0.7831 nhưng rất yếu ở client nhỏ (C1 0.7570). Hybrid cao hơn cả hai thành phần ở mọi client: GNN federated học từ chuỗi sự kiện chi tiết, LightGBM học từ đặc trưng tổng hợp, hai nguồn bổ sung cho nhau.
- Hybrid chỉ dùng GNN (FedAvg + Ditto) tăng nhẹ (+0.0009) nhưng sửa được nhược điểm của Ditto ở C4. Phần lớn mức tăng của hybrid tốt nhất vì vậy đến từ kết hợp mô hình graph với mô hình bảng, không chỉ từ cá nhân hóa.



Hình 3. ROC-AUC trên Test của từng client (mean ± std qua 3 seed); trong ngoặc là tỷ trọng khách hàng.

6.5. Phân tích concept shift

Để giải thích vì sao Personalized FL đơn lẻ chưa vượt FedAvg, ba phân tích được thực hiện trên kịch bản chính (dùng lại các mô hình đã train):



Hình 4. Ma trận chéo: mô hình Local-only của client i (hàng) dự đoán Test của client j (cột). Đường chéo in đậm.

- **Ma trận chéo:** mô hình của client lớn (C3, C4) dự đoán client nhỏ tốt hơn mô hình của chính client nhỏ đó (C0: mô hình riêng 0.7491, mô hình ngoại tốt nhất 0.7690; C1: 0.7463 so với 0.7651). Khác biệt chủ yếu do lượng dữ liệu, không phải do quan hệ rủi ro khác nhau.
- **Calibration theo client** trên Centralized LightGBM: kiểm định likelihood ratio cho hệ số chặn riêng ($p = 0.90$) và độ dốc riêng ($p = 0.85$) theo client đều không có ý nghĩa; độ dốc của từng client có khoảng tin cậy chứa 1.
- **Kiểm định tương tác:** thêm mã client vào LightGBM không tăng AUC có ý nghĩa ở client nào, kể cả khi bỏ các cột vùng. Kịch bản income_mix_a0.5 cho kết quả tương tự (LRT độ dốc $p = 0.21$).

Kết luận: các tổ chức khác nhau về quy mô và phân phối đặc trưng ($P_k(x)$), nhưng gần như cùng quan hệ rủi ro $P(y \mid x)$. Đây là điều kiện để một mô hình chung (FedAvg) đã gần tối ưu.

6.6. Stress test label_dirichlet_a0.5

Bảng 18. ROC-AUC trên Test theo client trong stress test (seed 42, chỉ baseline)

Mô hình	C0	C1	C2	C3	C4	TB	Kém nhất
Tỷ lệ vỡ nợ của client	4.8%	3.1%	72.1%	10.2%	3.4%		
Centralized LightGBM	0.7728	0.7910	0.8022	0.8024	0.8102	0.7926	0.7728
Centralized HeteroGNN	0.7701	0.7852	0.8002	0.7859	0.8032	0.7868	0.7701
Local-only	0.7074	0.7665	0.7669	0.7131	0.7708	0.7625	0.7074
FedAvg	0.7613	0.7692	0.7853	0.7618	0.7842	0.7708	0.7613

Khi lệch nhãn cực đoan, FedAvg tụt khoảng 0.016 AUC so với gom dữ liệu (so với 0.001 ở kịch bản chính), nên có chỗ để Personalized FL cải thiện. AUC/F1 gộp ở kịch bản này là con số ảo (Local-only đạt AUC gộp 0.8972) vì mô hình riêng học tỷ lệ nền của từng client; vì vậy đề tài chỉ dùng AUC theo client. Personalized FL và Hybrid chưa được chạy trên kịch bản này.

6.7. Kiểm định các giả thuyết

Bảng 19. Tổng hợp kiểm định giả thuyết

Giả thuyết	Kết quả	Mức chắc chắn
H1. FedAvg > Local-only	Đúng ở 5/5 client, 3/3 seed (+0.011 đến +0.032)	Chắc chắn
H2. Tổ chức nhỏ được lợi nhiều hơn	Đúng; C2 là ngoại lệ	Ổn định qua seed
H3. FedAvg ≈ Centralized	Đúng, trừ C2 (thấp hơn ở 3/3 seed)	Ổn định, trừ C2
H4. Personalized FL > FedAvg	PFL đơn lẻ: chưa đạt. Hybrid: đạt (+0.007, 3/3 seed)	Hybrid ổn định qua seed
H5. Kết luận ổn định qua seed	Đã lặp 3 seed cho HeteroGNN, Local-only, FedAvg, Ditto, Hybrid	Chưa đủ cho kiểm định chính thức

7. Thảo luận: trả lời các câu hỏi nghiên cứu

Q1. Heterogeneous graph so với mô hình bảng

Có, nhưng chưa vượt mô hình bảng mạnh nhất. HeteroGNN (0.7858) tốt hơn Logistic Regression (0.7832) dù node khách hàng chỉ dùng đặc trưng application, cho thấy graph học được thông tin từ lịch sử tín dụng chi tiết mà không cần thiết kế đặc trưng tổng hợp. LightGBM với 601 đặc trưng thủ công vẫn mạnh nhất (0.7931). Hai cách biểu diễn bổ sung cho nhau: kết hợp chúng (hybrid) cho kết quả tốt hơn từng loại riêng ở mọi client. Một lợi thế thực tế của graph là học trực tiếp từ dữ liệu quan hệ, dễ áp dụng khi các tổ chức có cùng schema nhưng khác cách thiết kế đặc trưng.

Q2. Federated Learning so với tự train và gom dữ liệu

FL có lợi rõ ràng và chi phí bảo mật gần như bằng 0. FedAvg tốt hơn Local-only ở mọi client và mọi seed, trung bình +0.0165 AUC; tổ chức nhỏ được lợi nhiều nhất (đến +0.03), AUC tổ chức kém nhất tăng từ 0.7422 lên 0.7731. So với gom dữ liệu, FedAvg chỉ kém trung bình 0.0012 và không khác biệt có ý nghĩa ở client nào; ngoại lệ là C2 (nhỏ nhất, lệch đặc trưng mạnh nhất) thấp hơn khoảng 0.009 ở mọi seed. Với lệch nhãn cực đoan (stress test), khoảng cách tăng lên khoảng 0.016.

Q3. Personalized FL so với FedAvg khi dữ liệu non-IID

Lợi thế của Personalized FL. Personalized FL có lợi khi client khác nhau không chỉ về phân phối đặc trưng mà về quan hệ rủi ro (concept shift), hoặc khi một client nhỏ và đặc thù bị mô hình chung bỏ qua. Bằng chứng trong đề tài:

- Ditto tăng ổn định ở C2 (+0.0063, 3/3 seed), client nhỏ nhất, chỉ có 3 vùng và lệch EXT_SOURCE_2 mạnh nhất; C2 cũng là client duy nhất mà FedAvg kém gom dữ liệu ở mọi seed.
- Hybrid cho mỗi client tự chọn mức cá nhân hóa: client lớn dựa nhiều vào mô hình riêng (w = 0.40), client nhỏ dựa nhiều vào tri thức chung (w = 0.65 – 0.75). Nhờ vậy cá nhân hóa không làm hại client lớn như Ditto với một λ chung, và nâng AUC ở cả 5 client.
- Khi lệch nhãn cực đoan, FedAvg tụt 0.016 AUC so với gom dữ liệu: đây là vùng mà Personalized FL được kỳ vọng có lợi rõ hơn (chưa thực nghiệm, xem mục 8).

Khi nào FedAvg vẫn phù hợp hơn. Khi các client chủ yếu khác nhau về quy mô và phân phối đặc trưng nhưng có cùng quan hệ P(y | x). Kịch bản chia theo vùng là ví dụ: không có concept shift (LRT p = 0.85 – 0.90), FedAvg đã gần chạm cận trên tập trung, nên Personalized FL đơn lẻ không còn chỗ cải thiện và còn có hại: Ditto giảm ở C4, FedProx giảm ở C3, Fine-tune overfit vào tập Validation nhỏ của C0. FedAvg cũng đơn giản hơn: một mô hình duy nhất, chi phí thấp (FedAvg 880 giây so với Ditto 5,158 giây), dễ quản lý và kiểm định mô hình, điều quan trọng trong ngân hàng. Với client rất nhỏ, mô hình riêng dễ overfit, nên nếu cá nhân hóa thì cần cơ chế tự điều chỉnh như hybrid.

Tóm lại: lợi ích của Personalized FL phụ thuộc vào loại non-IID chứ không chỉ mức non-IID. Lệch quy mô và lệch đặc trưng thì FedAvg đã đủ; concept shift và client đặc thù mới là nơi cá nhân hóa có lợi. Cách cá nhân hóa thích ứng theo từng client (hybrid) an toàn hơn cách cá nhân hóa đồng đều (Ditto với một λ chung).

Ý nghĩa thực tiễn

- Các tổ chức tín dụng địa phương nhỏ có lợi nhiều nhất khi tham gia liên kết FL (đến +0.03 AUC).
- Tổ chức nên kiểm tra concept shift (calibration theo client, ma trận chéo) trước khi đầu tư vào cá nhân hóa.
- Hybrid cho phép mỗi tổ chức giữ mô hình bảng sẵn có (thường đã được kiểm định nội bộ) và kết hợp với mô hình federated, không cần thay thế hệ thống hiện tại.

8. Hạn chế và hướng phát triển

Bảng 20. Hạn chế và hướng phát triển

Hạn chế	Hướng phát triển
Kịch bản chính gần như không có concept shift; Personalized FL và Hybrid chưa chạy trên kịch bản non-IID mạnh	Chạy Personalized FL và Hybrid trên label_dirichlet_a0.5 và income_mix_a0.5; quét α thuộc {0.1; 1; 5}
REGION_POPULATION_RELATIVE làm mã vùng là suy luận từ dữ liệu ẩn danh	Ghi rõ là giả định; kiểm tra độ nhạy với cách chia khác
Mới lặp 3 seed huấn luyện và 1 lần lấy mẫu phân vùng; FedPer, FedProx, Fine-tune, Centralized LightGBM chỉ có 1 seed	Tăng lên 5 seed, lặp lại bước chia client với nhiều seed
Hybrid dùng chung Validation cho early stopping, chọn w và threshold	Tách tập hiệu chỉnh riêng cho w
Một phần mức tăng của hybrid đến từ mô hình bảng, không thuần cá nhân hóa	So sánh với federated gradient boosting; hybrid với mô hình bảng federated
Siêu tham số chưa tune (λ, μ, kiến trúc HeteroGNN)	Tune λ thuộc {0.01; 0.1; 1}, μ thuộc {0.001; 0.01}; thêm attention, mã hóa thời gian, pos_weight
Mọi tổ chức có chung schema; mỗi khách hàng chỉ thuộc một tổ chức	Thử làm nhiễu, bỏ đặc trưng ở một số client; khách hàng trùng giữa các bên là bài toán vertical FL
Chưa có cơ chế bảo mật bổ sung	Secure aggregation, differential privacy cho trọng số và thống kê

9. Kết luận

Đề tài xây dựng pipeline hoàn chỉnh cho bài toán dự đoán vỡ nợ trên dữ liệu quan hệ trong bối cảnh Federated Learning: từ xử lý dữ liệu mồ côi, dựng heterogeneous graph 26.6 triệu node, chia dữ liệu cho 5 tổ chức theo địa bàn không dùng nhãn, đến huấn luyện và đánh giá có kiểm soát 13 mô hình trên cùng tập Test.

- Heterogeneous graph học được thông tin từ lịch sử tín dụng chi tiết (HeteroGNN 0.7858 > Logistic Regression 0.7832), nhưng LightGBM với đặc trưng thủ công vẫn mạnh nhất (0.7931).
- Federated Learning cải thiện ổn định mọi tổ chức so với tự huấn luyện, đặc biệt tổ chức nhỏ, và gần bằng gom dữ liệu: chi phí của việc không chia sẻ dữ liệu gần như bằng 0.
- Personalized FL không tự động tốt hơn FedAvg. Khi các tổ chức có cùng quan hệ rủi ro, FedAvg phù hợp hơn; cá nhân hóa chỉ có lợi ở tổ chức nhỏ và đặc thù.
- Hybrid Personalized FL, cho mỗi tổ chức tự chọn mức kết hợp giữa mô hình federated và mô hình riêng, đạt 0.7905 AUC, hơn FedAvg ở mọi seed, vượt HeteroGNN tập trung và gần bằng LightGBM tập trung mà không chia sẻ dữ liệu.

Bước tiếp theo quan trọng nhất là kiểm chứng Personalized FL và Hybrid trên các kịch bản có concept shift và lệch nhãn mạnh, để xác định định lượng khi nào cá nhân hóa bắt đầu có lợi.

Tài liệu tham khảo

[1] Arivazhagan, M. G., Aggarwal, V., Singh, A. K., & Choudhary, S. (2019). Federated Learning with Personalization Layers. arXiv:1912.00818.

[2] Deng, Y., Kamani, M. M., & Mahdavi, M. (2020). Adaptive Personalized Federated Learning. arXiv:2003.13461.

[3] Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Inductive Representation Learning on Large Graphs. NeurIPS.

[4] Hsu, T.-M. H., Qi, H., & Brown, M. (2019). Measuring the Effects of Non-Identical Data Distribution for Federated Visual Classification. arXiv:1909.06335.

[5] Kairouz, P., McMahan, H. B., et al. (2021). Advances and Open Problems in Federated Learning. Foundations and Trends in Machine Learning.

[6] Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS.

[7] Li, Q., Diao, Y., Chen, Q., & He, B. (2022). Federated Learning on Non-IID Data Silos: An Experimental Study. ICDE.

[8] Li, T., Sahu, A. K., Zaheer, M., et al. (2020). Federated Optimization in Heterogeneous Networks (FedProx). MLSys.

[9] Li, T., Hu, S., Beirami, A., & Smith, V. (2021). Ditto: Fair and Robust Federated Learning Through Personalization. ICML.

[10] McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS.

[11] Home Credit Group (2018). Home Credit Default Risk. Kaggle competition.

[12] Chính phủ Việt Nam (2023). Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân.